



UNIVERSITÀ DEGLI STUDI
DI MILANO

INFORMATICA E BIOSTATISTICA

Anno Accademico 2024-2025

Dott. Alberto Bertoncini



UNIVERSITÀ
DEGLI STUDI
DI MILANO

MISURE DI TENDENZA CENTRALE

MEDIA

MODA

MEDIANA

POPOLAZIONE E CAMPIONE

POPOLAZIONE: include tutti i rappresentanti di un particolare gruppo

Tutti i bovini, tutti i bovini da carne, tutti i bovini piemontesi, l'altezza di ciascun animale

CAMPIONE: è un sottogruppo estratto dalla popolazione

Popolazioni reali e ipotetiche

- 1) Siamo interessati all'IMPG nei suini Landrace: **popolazione reale**
- 2) Siamo interessati all'effetto di una dieta sperimentale nei suini Landrace, testeremo la dieta su un campione di suini Landrace estratto da un'ipotetica popolazione alimentata con quella dieta: **popolazione ipotetica**

SIMBOLI MATEMATICI

Pedice: solitamente i o j associato ad una variabile.

Significa la i-esima osservazione della variabile x

$$X_i$$

Sommatoria: l'espressione si legge "sommatoria, per i che va da 1 a n, degli i-esimi valori della variabile X"

$$\sum_{i=1}^n X_i$$

SIMBOLI MATEMATICI

Esempio. La variabile x assume i seguenti 5 valori. Quindi $n = 5$

i	x
1	3
2	8
3	4
4	2
5	10.7

$$\sum_{i=1}^5 x_i = x_1 + x_2 + x_3 + x_4 + x_5 = 3 + 8 + 4 + 2 + 10.7 = 27.7$$

MEDIA

E' una misura della tendenza dei dati ad aggregarsi intorno ad un valore centrale.

Se i dati rappresentano l'intera popolazione misurabile, la media viene simbolizzata da lettera greca (mu) μ

Se invece i dati sono un campione di n osservazioni il simbolo (x sovrabarrato) $\bar{x}$

A livello di calcolo sono identiche, la somma delle osservazioni diviso il numero

$$\mu = \bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

NB. l'unità di misura è la stessa della variabile in esame

MEDIA

Riprendendo un esempio precedente vediamo come calcolare l'**ACCURATEZZA** con l'utilizzo della media

Si vuole verificare l'accuratezza di un metodo di determinazione della glicemia del cane.

Si esamina per 9 volte una soluzione di glucosio a concentrazione nota (90mg/dl) e si ottengono i seguenti valori:

94, 90, 93, 86, 96, 98, 88, 90, 93

Media delle misurazioni: $828/9 = 92 \text{ mg/dl}$

Accuratezza: $\text{media} - \text{valore vero} = 92 - 90 = 2 \text{ mg/dl}$

Inaccuratezza: $\text{accuratezza}/\text{valore vero} = 2/90 = 0.022 \text{ (2.2\%)}$

MEDIANA

Valore che divide l'area di distribuzione della variabile in due parti equivalenti (da una parte e dall'altra di questo valore abbiamo lo stesso numero di osservazioni).

Esempio: Uno studente ha preso, nell'ultima classe di liceo, i seguenti voti in matematica:

2, 4, 6, 8, 2, 3, 5, 7, 7

Ordiniamo le 9 osservazioni:

2, 2, 3, 4, **5**, 6, 7, 7, 8.

La mediana è il valore che sta al centro della distribuzione (5).

La media invece è 4,9.

MEDIANA

Immaginiamo che lo studente avesse preso 10 voti:

7, 6, 7, 8, 2, 8, 9, 7, 10, 9

Ordiniamo le 9 osservazioni:

2, 6, 7, 7, **7, 8**, 8, 9, 9, 10

La mediana sarà il valore medio dei due valori centrali, in questo caso
 $(7+8)/2 = 7,5$

La media è pari a 7,3

Se, al posto del 10, ci fosse un valore che si discosta molto dagli altri,
es. 100, la mediana sarebbe rimasta 7,5 mentre la media sarebbe
diventata 16,4

**La mediana è un parametro statistico che risente meno della
presenza di valori anomali (outlier)**

MEDIANA

Formule per il calcolo della mediana

Per n (dispari) osservazioni la mediana corrisponde all' i -esima osservazione.

$$i = \frac{n + 1}{2}$$

Per n (pari) osservazioni la mediana corrisponde alla media tra i valori i -esimo e $i+1$ -esimo

ESERCIZIO

Calcolare media e mediana della seguente sequenza

1	2	2	2	10	10	10
---	---	---	---	----	----	----

ESERCIZIO

Usando le formule troviamo:

$$\text{Media} = 5.29$$

$$\text{Mediana} = 2$$

MODA

E' il valore della variabile relativo alla classe di maggior frequenza

4
5
7
8
8
7
7
6
5
5
5
4
3
2

Si ordinano i dati

2
3
4
4
5
5
5
5
6
7
7
7
8
8


MODA = 5

Anche la moda si esprime nella stessa unità di misura della variabile.


MODA

In caso di parità di frequenza di due (o più) valori si possono mantenere entrambi, o eseguire un'ulteriore aggregazione

UNIMODALE



BIMODALE




MEDIA MODA MEDIANA

VARIABILI	MEDIA	MEDIANA	MODA
Quantitative	Sì	Sì	Sì
Qualitative Ordinali	NO	Sì	Sì
Qualitative Nominali	NO	NO	Sì

MEDIA MODA MEDIANA

	DEFINIZIONE	VANTAGGI	SVANTAGGI
MEDIA	$\frac{\text{somma dei dati}}{\text{numero dei dati}}$	adatta a manipolazioni matematiche	molto influenzata dai valori estremi
MEDIANA	livello di misura al di sotto del quale cade la metà dei dati	non influenzata dai valori estremi	non adatta a manipolazioni matematiche
MODA	valore che ricorre con maggiore frequenza	di significato facilmente intuibile	possibili distribuzioni bi-, tri-modali ecc.

MEDIA MODA MEDIANA



Il confronto tra le misure ci dà delle indicazioni sulla simmetria o asimmetria della distribuzione

- Distribuzione asimmetrica con coda a dx
- $\text{Moda} < \text{Mediana} < \text{Media}$
- Distribuzione asimmetrica con coda a sx
- $\text{Media} < \text{Mediana} < \text{Moda}$

MEDIA PONDERATA

Talvolta i dati, su cui si calcola la media, non contribuiscono equamente alla media finale, alcuni dati contribuiscono più di altri.

$$\text{Media Ponderata} = \bar{x} = \frac{\sum xw}{n}$$

E' quindi necessario calcolare la media ponderata per tener conto del diverso peso (w) dei dati

Due studenti di MedVet hanno preso nei singoli moduli del corso di 'Sc. Prop. Di base per la MV' i seguenti voti:

Modulo	CFU = w	Voto A = x	Voto B = x	w*x A	w*x B
Fisica	2	27	21	54	42
Chimica	3	21	25	63	75
Inf&Biostat	5	21	23	105	115
Totale	10	69	69	222	232
Media		23	23	22.2	23.2

MEDIA GEOMETRICA

Utilizzata quando la distribuzione dei dati è asimmetrica

Dopo la trasformazione logaritmica dei dati la distribuzione risulta più simmetrica, e quindi analizzabile con gli stimatori

Ad esempio, nel grafico si nota come la distribuzione dei pesi di 19 cavie (Guinea pig) sia asimmetrica:



Dopo trasformazione logaritmica, la distribuzione è più simmetrica



La media geometrica è l'antilogaritmo della media dei logaritmi dei singoli valori

Mediana = 474 g

Media log(peso) = 2.69

Media = 523 g

Media geometrica = $\text{antilog}(2.69) = 489.78 \text{ g}$

ESERCIZIO

Calcolare Media, Mediana e Moda (quando possibile) delle seguenti osservazioni

1) 12 15 25 18 15 4 16 15 13

2) 12 15 25 18 14 4 16 14 13 20

3) 12 13 20 12 12 13 13 12 13

4) verde rosso giallo giallo giallo verde rosso
verde giallo

ESERCIZIO

1) 12 15 25 18 15 4 16 15 13

-4, 12, 13, 15, 15, 15, 16, 18, 25

media= 14.78

mediana= 15

moda= 15

ESERCIZIO

2) 12 15 25 18 14 4 16 14 13 20

-4, 12, 13, 14, 14, 15, 16, 18, 20, 25

media= 15.1

mediana= 14.5

moda= 14

ESERCIZIO

3) 12 13 20 12 12 13 13 12 13

-12, 12, 12, 12, 13, 13, 13, 13, 20

media= 13.33

mediana= 13

moda= 12, 13

ESERCIZIO

4) verde rosso giallo giallo giallo verde

rosso verde giallo

-giallo, giallo, giallo, giallo, rosso, rosso

verde, verde, verde

media= NA,

mediana= rosso (se ordine alfabetico),

moda= giallo

RANGE

Differenza tra il valore massimo e minimo della variabile in studio

Serie: 2, 3, 4, 4, 5, 5, 5, 5, 6, 7, 7, 7, 8, 8

Range: $8 - 2 = 6$

VARIANZA

La varianza è una misura della dispersione dei dati (x_i) intorno alla media ed definita come la **media degli scarti quadratici**

Nel caso di **varianza** della popolazione si indica con: σ_x^2

Nel caso di **varianza campionaria** si indica con: s_x^2

É possibile indicarla come funzione $V()$

La formula per la **varianza** è:

$$\sigma_x^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$$

VARIANZA

Per semplicità e correttezza di calcolo la varianza viene calcolata con una formula equivalente alla precedente che però richiede meno operazioni e approssimazioni e di cui pertanto è obbligatorio l'uso.

$$\sigma_x^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}}{n}$$

DEVIAZIONE STANDARD

La deviazione standard è la radice quadrata della varianza


Parametro	Popolazione	Campione
Varianza	$\sigma_x^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$ $\sigma_x^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{(\sum x_i)^2}{n}}{n}$	$s_x^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$ $s_x^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{(\sum x_i)^2}{n}}{n - 1}$
Deviazione standard	$\sigma_x = \sqrt{\sigma_x^2}$	$s_x = \sqrt{s_x^2}$
Devianza ss(x)	Numeratore della varianza	Numeratore della varianza
GRADI DI LIBERTÀ	Denominatore della varianza	Denominatore della varianza

DEVIAZIONE STANDARD


Perchè l'utilizzo di $n-1$ al denominatore nel caso della varianza campionaria:

- Non è possibile ottenere una stima della varianza da un campione di grandezza 1, in quanto non ci sarebbe variazione
- Quando scegliamo un campione casuale, questo non conterrà verosimilmente troppi valori estremi della popolazione e quindi la deviazione standard campionaria tenderà a sottostimare la vera deviazione standard. Per correggere questa sottostima dovremmo dividere per $n-1$ invece che per n
- Motivazioni matematiche legate alla costruzione dello stimatore e al suo valore atteso (non è parte del programma del corso)

INDICI DI VARIABILITÀ



La deviazione standard è maggiore quando la distribuzione ha una maggior estensione verso i valori più estremi



INDICI DI VARIABILITÀ

Esempio numerico:

i	x_i	μ (o $\bar{x}$)	$(x_i - \bar{x}) = e_i$	$(x_i - \bar{x})^2 = e_i^2$
1	3	5.54	-2.54	6.4516
2	8	5.54	2.46	6.0516
3	4	5.54	-1.54	2.3716
4	2	5.54	-3.54	12.5316
5	10.7	5.54	5.16	25.6256
Totale	27.7	27.7	0.00	54.032

$$\sigma^2 = 54.032 / 5 = 10.8064, \sigma = 3.2873;$$

$$s^2 = 54.032 / 4 = 13.5080, s = 3.6753$$

INDICI DI VARIABILITÀ

Calcolo rapido:

i	x_i	x_i^2
1	3	9
2	8	64
3	4	16
4	2	4
5	10.7	114.49
Totale	27.7	207.49

$$\sigma^2 = \frac{\sum x_i^2 - \frac{(\sum x_i)^2}{n}}{n} = [207.49 - (27.7^2/5)] / 5 = 54.032/5 = 10.8064$$

$$\sigma = 3.2873$$

$$s^2 = \frac{\sum x_i^2 - \frac{(\sum x_i)^2}{n}}{n-1} = 54.032 / 4 = 13.508$$

$$s = 3.6753$$

ESERCIZIO

Considerato il seguente campione di dati sulla durata della mungitura (x) di una popolazione di bovine adulte si calcoli: la varianza, la deviazione standard e la devianza.

2	3.3	5.4	3.4	5.15	7	4.2	4.1
---	-----	-----	-----	------	---	-----	-----

ESERCIZIO

Considerato il seguente campione di dati sulla durata della mungitura (x) di una popolazione di bovine adulte si calcoli: la varianza, la deviazione standard e la devianza.

2	3.3	5.4	3.4	5.15	7	4.2	4.1
---	-----	-----	-----	------	---	-----	-----

$$s_x^2 = 2.34$$

$$s_x = 1.53$$

$$SS_x = 16.37$$

COEFFICIENTE DI VARIAZIONE

$$CV = \frac{\text{DEVIAZIONE STANDARD}}{\text{MEDIA CAMPIONARIA}}$$

- È una misura adimensionale della variabilità di una misurazione (l'u.d.m., uguale sia al numeratore che al denominatore si elide)
- È una percentuale
- Permette di valutare la dispersione intorno alla media

Variabile	Razza	Media	D.S.	C.V. (%)
Latte (kg)*	Frisona Italiana	9896	2255	22.8
Latte (kg)*	Bruna	7531	2036	27.0
Latte (kg)*	Sarda	324	101	31.2
HCT**	Bracco Italiano	47.10	5.58	11.8
HCT**	Segugio Italiano	43.66	4.43	10.1

*Bollettino dei controlli della produttività del latte, 2020

**Miglio et al., 2020. Animals, 10, 212

ESERCIZIO

In un campione di 25 pecore adulte viene misurata la ventilazione polmonare a riposo (l/min):

8.3	8	9.9	6.1	5.5	10.3	6.5	7.6	7.6
7.6	6.9	10.3	7.8	7.3	8.9	10.1	7.6	9.1
8.3	4.8	10.2	6.5	9.1	7	11.9		

Calcolare: media, mediana, moda, range, devianza, varianza, deviazione standard, c.v.

Fare istogramma di frequenza. Calcolare le frequenze relative.

Sono riportati i valori di ventilazione polmonare elevati al quadrato

68.89	64	98.01	37.21	30.25	106.09	42.25	57.76	57.76
57.76	47.61	106.09	60.84	53.29	79.21	102.01	57.76	82.81
68.89	23.04	104.04	42.25	82.81	49	141.61		

Ventilazione polmonare (l/min) ► Variabile x

$$\sum_{i=1}^{25} x = 203.2 \frac{l}{min} \quad \sum_{i=1}^{25} x^2 = 1721.24 \left(\frac{l}{min} \right)^2$$

ESERCIZIO

$$\text{Media} = \frac{203.2}{25} = 8.128 \text{ l/min}$$

$$\sum_{i=1}^{25} x = 203.2 \frac{\text{l}}{\text{min}}$$
$$\sum_{i=1}^{25} x^2 = 1721.24 \left(\frac{\text{l}}{\text{min}}\right)^2$$

Per calcolare **mediana e moda**, occorre ordinare le osservazioni per la variabile x in ordine ascendente

4.8	5.5	6.1	6.5	6.5	6.9	7	7.3	7.6
7.6	7.6	7.6	7.8	8	8.3	8.3	8.9	9.1
9.1	9.9	10.1	10.2	10.3	10.3	11.9		

N = 25 dispari ► 1 valore per la mediana ► $i = \frac{25+1}{2} = 13$

Mediana = 13° valore = 7.8 l/min

Moda = 7.6 l/min

Range = 11.9 – 4.8 = 7.1 l/min

ESERCIZIO

Varianza

$$s_x^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{(\sum x_i)^2}{n}}{n}$$

$$s_x^2 = \frac{1721.21 - \frac{(203.2)^2}{25}}{24} = 2.902 \text{ (l/min)}^2$$

$$\sum_{i=1}^{25} x = 203.2 \frac{\text{l}}{\text{min}}$$
$$\sum_{i=1}^{25} x^2 = 1721.24 \left(\frac{\text{l}}{\text{min}}\right)^2$$

Deviazione standard

$$s_x = \sqrt{s_x^2}$$
$$s_x = \sqrt{2.902} = 1.703 \text{ l/min}$$

$$\text{Coefficiente di variabilità} = \frac{s_x}{x}$$

$$\text{CV} = \frac{1.703}{8.128} = 0.209$$

DISTRIBUZIONI

ASIMMETRIA


Caratterizza il grado di asimmetria di una distribuzione intorno alla sua media. L'asimmetria positiva indica una distribuzione con una coda asimmetrica che si estende verso i valori più positivi (coda a destra).

L'asimmetria negativa indica una distribuzione con una coda asimmetrica che si estende verso i valori più negativi (coda a sinistra).


CURTOSI

La curtosi caratterizza la punta massima o minima relativa di una distribuzione rispetto alla distribuzione normale. Una curtosi positiva indica una distribuzione relativa verso il punto massimo. Una curtosi negativa indica invece una distribuzione relativa piatta.

DISTRIBUZIONI



0,809052
asimmetria positiva
coda a destra




-0,80905
asimmetria negativa
coda a sinistra


Dati di origine:

x	f. assolute
1	3
2	6
3	5
4	3
5	2
6	1
7	1

X	f. assolute
1	1
2	1
3	2
4	3
5	5
6	6
7	3



0,274828
curtosi positiva
distribuzione leptocurtica



-0,76485
curtosi negativa
distribuzione platicurtica

Dati di origine:

x	f. assolute
1	1
2	2
3	2
4	7
5	2
6	2
7	1

x	f. assolute
1	1
2	2
3	2
4	3
5	2
6	2
7	1

BOX-PLOT

Fornisce una descrizione sintetica della distribuzione dei valori

Riporta:

- 1) Mediana
- 2) 1° e 3 quartile
- 3) Valori minimo e massimo

