



UNIVERSITÀ DEGLI STUDI
DI MILANO

INFORMATICA E BIOSTATISTICA

Anno Accademico 2024-2025

Dott. Alberto Bertoncini



UNIVERSITÀ
DEGLI STUDI
DI MILANO

INTERVALLI DI CONFIDENZA

Inferenza Statistica

Processo attraverso il quale si traggono conclusioni su un'intera popolazione in base ad un campione

È molto difficile conoscere i parametri della popolazione. Il campionamento comporta due tipi di errori riducibili ma ineliminabili:

Gli **errori casuali** variano in modo imprevedibile da una misura all'altra e influenzano il risultato qualche volta per eccesso, qualche altra volta per difetto.

Gli **errori sistematici** avvengono sempre nello stesso senso: o sempre per eccesso, o sempre per difetto.

- Non si può quindi affermare con certezza che i risultati ottenuti su un campione siano trasferibili ad una popolazione, ma si può generalizzare in termini medi utilizzando opportuni metodi statistici

INTERVALLI DI CONFIDENZA

CAMPIONE: sottoinsieme della popolazione

Ci permette di conoscere non i veri parametri della popolazione (es. vera media, vera varianza), ma delle statistiche o stimatori di tali parametri

Occorre:


- ☞ Scegliere il campione in modo corretto (per evitare bias, distorsione dello stimatore). Scelta random = ogni individuo deve avere la stessa probabilità di essere selezionato ► **riduzione dell'errore sistematico**
- ☞ Utilizzare un adeguato numero di unità campionarie ► **riduzione dell'errore casuale**
- ☞ **Elaborare in modo corretto gli stimatori**

E' necessario stabilire la precisione degli stimatori del campione
ERRORE STANDARD

ERRORE STANDARD DELLA MEDIA

Se si selezionano da una popolazione con media μ e deviazione standard σ tutti i possibili campioni di dimensione n , si ottiene una serie di valori costituiti da medie campionarie

Se ciascuna media è considerata come una singola osservazione, la distribuzione di probabilità di queste medie è denominata **distribuzione delle medie campionarie**



Estrazione di 4 campioni di dimensione pari a 100 da una popolazione con $\mu = 50$ kg e $\sigma = 10$ kg

ERRORE STANDARD DELLA MEDIA

La **distribuzione delle medie campionarie** ha 3 importanti proprietà:

- La media della distribuzione delle medie campionarie è uguale alla media μ della popolazione
- La deviazione standard della distribuzione delle medie campionarie è uguale a:
$$\frac{\sigma}{\sqrt{n}} = \sigma_{\bar{x}} = \text{Errore standard della media}$$
- La forma della distribuzione delle medie campionarie è normale


ERRORE STANDARD DELLA MEDIA

È direttamente
proporzionale alla
deviazione standard
della Popolazione

È inversamente
proporzionale alla radice
quadrata del numero
delle osservazioni

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

Distribuzione di 10000 medie
calcolate da 10000 campioni
di dimensione 100 estratti da
una popolazione con $\mu = 50$
kg e $\sigma = 10$ kg




ERRORE STANDARD DELLA MEDIA

C'è una minor variabilità tra le medie campionarie che tra le osservazioni individuali

All'aumentare di n , diminuisce la variabilità delle medie campionarie

Per n sufficientemente grande, la distribuzione delle medie si approssima alla normale (TEOREMA DEL LIMITE CENTRALE)


$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$



TEOREMA DEL LIMITE CENTRALE

Se n è sufficientemente grande, la distribuzione delle medie campionarie è approssimativamente normale

Sia data una popolazione numerica infinita di media μ e deviazione standard σ da cui vengono estratti dei campioni casuali formati ciascuno da n individui, con n abbastanza grande ($n > 30$). La distribuzione delle medie campionarie tende a una distribuzione gaussiana di media $\mu_{\bar{x}} = \mu$ e deviazione standard $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$



TEOREMA DEL LIMITE CENTRALE

Se n è sufficientemente grande, la distribuzione delle medie campionarie è approssimativamente normale

Poiché la distribuzione delle medie campionarie è approssimativamente normale con media μ e deviazione standard $\sigma/\sqrt{n}$, la distribuzione delle medie campionarie standardizzata è pari a:

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

Ed è normalmente distribuita con media 0 e deviazione Standard 1

Possiamo utilizzare le tabelle della distribuzione Z per fare inferenze sulla media della popolazione

NB: la notazione maiuscola indica la media dei valori della variabile casuale X , ovvero la media delle medie campionarie

TEOREMA DEL LIMITE CENTRALE

Quando si analizzano singoli valori provenienti da una distribuzione normale occorre utilizzare la **variabile standardizzata**:

$$Z = \frac{\overline{X} - \mu}{\sigma}$$

Quando si analizza la media ottenuta da un campione (o gruppo), si ha a che fare con medie campionarie e si utilizza la **media campionaria standardizzata**:

$$Z = \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

TEOREMA DEL LIMITE CENTRALE

La distribuzione campionaria delle medie è una distribuzione **ipotetica**

Possiamo considerare alcune caratteristiche della distribuzione campionaria delle medie per indicare quanto *buona* è la nostra stima

Miglior modo per testare la bontà di una media è calcolare

L'INTERVALLO DI CONFIDENZA DELLA MEDIA

Intervallo di possibili valori entro cui è compresa la media della popolazione


INTERVALLI DI CONFIDENZA

- * L'intervallo è compreso tra un limite superiore e uno inferiore
- * Se l'intervallo di confidenza è ampio, allora la media del campione è una stima piuttosto povera della media della popolazione
- * Se l'intervallo di confidenza è stretto, allora la media del campione è una buona stima della media della popolazione
- * Si considera solitamente un intervallo di confidenza del 95%
- * Possono essere considerati anche altri intervalli (90% o 99%)

INTERVALLI DI CONFIDENZA

Per una variabile normale standardizzata il 95% delle osservazioni è compreso tra -1.96 e 1.96, cioè:

$$P(-1.96 \leq Z \leq 1.96) = 0.95$$



* Intervallo di
confidenza:
* con σ nota

Le due aree tratteggiate $\rightarrow 2.5\% + 2.5\% = 5\% (\alpha)$

$$\bar{X} - 1.96 * \frac{\sigma}{\sqrt{n}}$$

$$\bar{X} + 1.96 * \frac{\sigma}{\sqrt{n}}$$


Limiti
dell'intervallo di
confidenza al 95%
della media della
popolazione

INTERVALLI DI CONFIDENZA

Significato e interpretazione dell'intervallo di confidenza

Siamo confidenti al 95% che l'intervallo osservato contenga la vera media della popolazione (ossia: vi è una probabilità pari al 95% che l'intervallo osservato contenga la vera media della popolazione)

Se immaginiamo di ripetere un campionamento 20 volte usando la stessa dimensione campionaria, si ottengono 20 differenti stime della media e 20 differenti intervalli di confidenza. I 20 intervalli di confidenza con la rispettiva media (simbolo del rombo) che oscillano intorno al valore fisso del vero parametro della popolazione (che non è noto), di questi 19 (pari al 95% dei 20 indicati) lo incrociano (e quindi il loro intervallo di valori, contiene il vero valore del parametro)



INTERVALLI DI CONFIDENZA

Significato e interpretazione dell'intervallo di confidenza

La varianza della produzione di latte in una popolazione di capre è pari a $\sigma^2 = 16940$ kg². Un campione di 15 capre selezionato da questa popolazione presenta una produzione media effettiva pari a 570 kg. Calcolare un intervallo di confidenza al 95% per la media della popolazione (μ)

$$\bar{X} - 1.96 \cdot \frac{\sigma}{\sqrt{n}} \quad \bar{X} + 1.96 \cdot \frac{\sigma}{\sqrt{n}}$$

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} = \frac{\sqrt{16940}}{\sqrt{15}} = 33.61$$

Limite inferiore: $570 - 1.96 \cdot 33.61 = 504.12$ kg

Limite superiore: $570 + 1.96 \cdot 33.61 = 635.88$ kg

INTERVALLI DI CONFIDENZA

Esercizio

Sulla base del seguente campione casuale estratto da una popolazione normale di varianza nota $\sigma^2 = 2.5$

2.0 1.6 2.5 2.4 2.0 3.1 1.3 2.2 1.8 1.1

determinare l'intervallo di confidenza di μ
al livello di probabilità $1 - \alpha = 0.95$

INTERVALLI DI CONFIDENZA

Esercizio

La media campionaria calcolata sui 10 elementi selezionati risulta $\bar{X} = 2$

$$\bar{x} \pm z_{0.025} \sqrt{\frac{\sigma^2}{n}} = 2 \pm 1.96 \sqrt{\frac{2.5}{10}} = (1.02, 2.98)$$

$Z_{0.025}$ perché si desidera una confidenza pari a 0.95, quindi escludiamo 0.05 diviso sull'estremo superiore e inferiore (0.025 l'uno)

I valori (sulla distribuzione normale standardizzata) per escludere 0.025 risultano (1.96, -1.96), che verrà moltiplicato per la deviazione standard delle media campionarie al fine di ottenere il corrispettivo valore non standardizzato

INTERVALLI DI CONFIDENZA

Esercizio

Il manager che si occupa del controllo di qualità di un'azienda che produce lampadine intende stimare la durata media delle lampadine facenti parte di un determinato lotto di produzione.

Si sa che la deviazione standard delle lampadine prodotte è pari a 100 ore.

Viene estratto un campione di 64 lampadine, che forniscono una durata media pari a 350ore.

Rispondere alle seguenti domande:

- 1) Calcolare un intervallo di confidenza al livello di fiducia del 95% per la durata media delle lampadine;
- 2) Può il produttore affermare che la durata media delle lampadine è pari a 400ore?

INTERVALLI DI CONFIDENZA

$$n = 64 \quad \overset{\text{Esercizio}}{\bar{x}} = 350 \quad \sigma = 100$$

Vogliamo una confidenza del 95%, ovvero escludere lo 0.05 (α) della distribuzione più lontana dalla media e considerare lo 0.95 ($1-\alpha$) dell'area. Escludiamo le due code (positiva e negativa) corrispondenti a $z_{(\alpha/2)}=z_{0.025}=z_{0.975}$ (uguali in quanto simmetrica)

Un modo per scrivere l'intervallo di confidenza consiste nel posizionare la media tra i due limiti (inferiore e superiore), essendone sicuri che lo $(1-\alpha)=0.95$ dell'area ricadrà in questo intervallo

$$\bar{x} - z_{0.025} \cdot \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + z_{0.975} \cdot \frac{\sigma}{\sqrt{n}}$$

$$450 - 1.96 \cdot \frac{100}{\sqrt{64}} \leq \mu \leq \bar{x} + 1.96 \cdot \frac{100}{\sqrt{64}}$$

$$325.5 \leq \mu \leq 374.5$$

ERRORE STANDARD DEL CAMPIONE

In genere non si conosce σ . Per calcolare l'ES del campione si utilizza s

$$ES_{\bar{x}} = \frac{s}{\sqrt{n}}$$

L'errore standard della media, stimato in base ai dati, è la deviazione standard del campione (s) divisa per la radice quadrata della dimensione del campione (n)

Esempio

La produzione media di latte di 256 bovine Holstein Friesian è 9414 kg, con deviazione standard pari a 2352 kg.

Trovare l'errore standard:

$$ES_{\bar{x}} = \frac{2352}{\sqrt{256}} = 147 Kg$$

ERRORE STANDARD DEL CAMPIONE

Errore standard o deviazione standard?

Media $\pm$ DS

- Misura lo scostamento dalla media
- Da indicazione di quanto le osservazioni siano vicini alla media
- È utilizzata per costruire un range in cui si trova la maggior parte delle osservazioni di una popolazione

Media $\pm$ ES

- È una misura della precisione della media del campione come stima della media della popolazione
- Da indicazione di quanto vicino alla media della popolazione sia la media del campione
- È utilizzata per calcolare l'intervallo di confidenza che permette di giudicare la precisione della stima della media della popolazione

INTERVALLO DI CONFIDENZA


Intervallo di confidenza con σ non nota

- Finora si è assunto che, per una popolazione con μ ignota, σ fosse nota
- In realtà se μ è ignota verosimilmente anche σ è ignota
- Non utilizza la deviazione standard della popolazione, σ , ma quella del campione s e si ottiene il rapporto t :

$$z = \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{N}}} \rightarrow t = \frac{\overline{X} - \mu}{\frac{s}{\sqrt{N}}}$$

- t non segue la distribuzione di una normale standardizzata, ma la **distribuzione t di Student**

DISTRIBUZIONE T DI STUDENT




Nel grafico: distribuzione t di Student per g.l.=1 (blu, indicatore = triangolo) con sovrapposta la normale (nera).

- È simmetrica e a forma di campana, simile alla normale, ma più piatta e con le code più spesse
- È caratterizzata dai gradi di libertà (GL) pari a $(n-1)$
- L'area sottesa dalla curva è pari a 1

Per ogni possibile valore dei gradi di libertà, c'è una diversa distribuzione t

DISTRIBUZIONE T DI STUDENT



Distribuzione t per differenti GL
All'aumentare dei GL la distribuzione t si approssima
alla normale (Teorema del limite centrale)

DISTRIBUZIONE T DI STUDENT

DISTRIBUZIONE DEL T DI STUDENT (test bilaterale)

g.l.	α								
	0.5	0.4	0.2	0.1	0.05	0.025	0.01	0.005	0.001
1	1.000	1.376	3.078	6.314	12.706	25.452	63.657		
2	0.816	1.061	1.886	2.920	4.303	6.205	9.925	14.089	31.598
3	0.765	0.978	1.638	2.353	3.182	4.177	5.841	7.453	12.941
4	0.741	0.941	1.533	2.132	2.776	3.495	4.604	5.598	8.610
5	0.727	0.920	1.476	2.015	2.571	3.163	4.032	4.773	6.868
6	0.718	0.906	1.440	1.943	2.447	2.969	3.707	4.317	5.959
7	0.711	0.896	1.415	1.895	2.365	2.841	3.499	4.029	5.408
8	0.706	0.889	1.397	1.860	2.306	2.752	3.355	3.833	5.041
9	0.703	0.883	1.383	1.833	2.262	2.685	3.250	3.690	4.780
10	0.700	0.879	1.372	1.812	2.228	2.634	3.169	3.581	4.587
11	0.697	0.876	1.363	1.796	2.201	2.593	3.106	3.497	4.437
12	0.695	0.873	1.356	1.782	2.179	2.560	3.055	3.428	4.318
13	0.694	0.870	1.350	1.771	2.160	2.533	3.012	3.372	4.221
14	0.692	0.868	1.345	1.761	2.145	2.510	2.977	3.326	4.140
15	0.691	0.866	1.341	1.753	2.131	2.490	2.947	3.286	4.073
16	0.690	0.865	1.337	1.746	2.120	2.473	2.921	3.252	4.015
17	0.689	0.863	1.333	1.740	2.110	2.458	2.898	3.222	3.965
18	0.688	0.862	1.330	1.734	2.101	2.445	2.878	3.197	3.922
19	0.688	0.861	1.328	1.729	2.093	2.433	2.861	3.174	3.883
20	0.687	0.860	1.325	1.725	2.086	2.423	2.845	3.153	3.850
21	0.686	0.859	1.323	1.721	2.080	2.414	2.831	3.135	3.819
22	0.686	0.858	1.321	1.717	2.074	2.405	2.819	3.119	3.792
23	0.685	0.858	1.319	1.714	2.069	2.398	2.807	3.104	3.768
24	0.685	0.857	1.318	1.711	2.064	2.391	2.797	3.091	3.745
25	0.684	0.856	1.316	1.708	2.060	2.385	2.787	3.078	3.725
26	0.684	0.856	1.315	1.706	2.056	2.379	2.779	3.067	3.707
27	0.684	0.855	1.314	1.703	2.052	2.373	2.771	3.057	3.689
28	0.683	0.855	1.313	1.701	2.048	2.368	2.763	3.047	3.674
29	0.683	0.854	1.311	1.699	2.045	2.364	2.756	3.038	3.659
30	0.683	0.854	1.310	1.697	2.042	2.360	2.750	3.030	3.646
40	0.681	0.851	1.303	1.684	2.021	2.329	2.704	2.971	3.551
50	0.679	0.849	1.299	1.676	2.009	2.311	2.678	2.937	3.496
60	0.679	0.848	1.296	1.671	2.000	2.299	2.660	2.915	3.460
70	0.678	0.847	1.294	1.667	1.994	2.291	2.648	2.899	3.435
80	0.678	0.846	1.292	1.664	1.990	2.284	2.639	2.887	3.416
90	0.677	0.846	1.291	1.662	1.987	2.280	2.632	2.878	3.402
100	0.677	0.845	1.290	1.660	1.984	2.276	2.626	2.871	3.390

La tabella riporta:
 - IN ALTO: aree sotto la curva solo per alcune probabilità α
 - A SINISTRA: i GL

Per un determinato valore di GL, il valore della tabella rappresenta il valore di t_{n-1} che delimita il $\alpha\%$ della distribuzione (il $\alpha/2\%$ perparte)