



UNIVERSITÀ DEGLI STUDI
DI MILANO

INFORMATICA E BIOSTATISTICA

Anno Accademico 2024-2025



CONFRONTI TRA MEDIE

TIPOLOGIE DI STUDIO:

- 1) Media di un singolo gruppo (campione) confrontata con la **media della popolazione**
- 2) Questo con due casi distinti di situazioni:
 - σ noto
 - σ ignoto
- 3) Medie di due gruppi di osservazioni (campioni) che possono essere
- 4) **Indipendenti**: raccolti per due popolazioni o trattamenti
- 5) **Appaiati**: (a coppie): i dati possono essere raccolti
 - Per due trattamenti a ciascuna unità campionaria
 - Per due unità campionarie appaiate in base ad alcune variabili (es: età peso, ecc...)

CONFRONTI TRA MEDIE

Media di un singolo gruppo confrontata con la media della popolazione – **σ noto**

Si utilizza la statistica

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{N}}} \quad H_0 : \bar{X} = \mu$$

Si ottiene il **P-value** dalle tavole della distribuzione Z

Si verifica l'intervallo di confidenza al 95% utilizzando le formule note:

$$\bar{X} \pm 1.96 \frac{\sigma}{\sqrt{n}}$$

CONFRONTI TRA MEDIE

Problema:

Variabile = concentrazione di urea nel sangue di bovini

Campione di 10 animali: media = 22 mg/100 ml.

In letteratura: ampia indagine $\rightarrow \mu = 25; \sigma^2 = 45$.

Domanda: posso affermare che il campione proviene da una popolazione con media 25 e varianza 45?

Ipotesi nulla: il campione proviene dalla popolazione normalmente distribuita con $\mu = 25; \sigma^2 = 45$

$H_0: \mu = \mu_0 = 25 \text{ mg}$ μ = media del campione

μ_0 = media della popolazione

Livello di significatività: $\alpha = 0.05$


Si utilizza il test a 2 code

Valore critico: $Z = 1.96, Z = -1.96$

$$\sigma_{\bar{x}} = \sqrt{\frac{45}{10}} = 2.12$$

$$(1) z = \frac{\bar{x} - \mu}{\sigma_{\bar{x}}} = \frac{22 - 25}{2.12} = -1.41$$

$$(2) P(z = -1.41) = 0.079$$



CONFRONTI TRA MEDIE

Dai risultati ottenuti sia con la statistica test (1) sia con il P-value (2) si giunge alla medesima conclusione

(1) z non supera il valore critico di -1.96

► accetto H_0

(2) $P(z = -1.41) = 0.079$, $0.079 \times 2 = 0.158 > \alpha = 0.05$

► accetto H_0

Accetto l'ipotesi nulla (ossia la media del campione è uguale a quella della popolazione)

Gli intervalli di confidenza al 95% della media della popolazione sono:

$$\bar{X} \pm 1.96 \frac{\sigma}{\sqrt{n}}$$

$$l_1 = 22 - 1.96 * 2.12 = 17.84 \text{ mg/100 ml}$$

$$l_2 = 22 + 1.96 * 2.12 = 26.15 \text{ mg/100 ml}$$

Siamo fiduciosi al 95% che i limiti di 17.84 e 26.15 mg/100 ml contengono la media della popolazione che è pari a 25 mg/100ml

CONFRONTI TRA MEDIE

Media di un singolo gruppo confrontata con la media della popolazione – σ non noto

Si utilizza la statistica

$$t = \frac{\overline{X} - \mu}{\frac{s}{\sqrt{N}}}$$

$$H_0 : \overline{X} = \mu$$

Si ottiene il **P-value** dalle tavole della distribuzione t

Si verifica l'intervallo di confidenza al 95% utilizzando le formule note

$$\overline{X} \pm t_{(n-1, \alpha=0.05)} \frac{s}{\sqrt{n}}$$

CONFRONTI TRA MEDIE

In un campione di 36 suini è stato rilevato l'incremento medio ponderale giornaliero (IMPG, Daily Weight Gain = DWG) e si sono ottenuti i seguenti risultati

$$\bar{X} = 599.194g \quad s = 18.656g \quad Es = \frac{s}{\sqrt{n}} = 3.109$$

L'IMPG calcolato sulla popolazione è di 607g

C'è differenza tra i 2 valori?

$$H_0 : \bar{X} = \mu \text{ ossia } \bar{X} - \mu = 0 \quad t = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} = \frac{599.194 - 607}{3.109} = -2.51$$

Dalle tavole: $t_{(\alpha=0.05, 35GL)}$ compreso tra 2.042 e 2.021

30	0.683	0.854	1.310	1.697	2.042	2.360	2.750	3.030	3.646
40	0.681	0.851	1.303	1.684	2.021	2.329	2.704	2.971	3.551

$T=2.51 > t \text{ tabulato} \rightarrow \text{Rifiuto } H_0$

CONFRONTI TRA MEDIE

L'intervallo di confidenza al 95%:

$$\overline{X} \pm t_{(n-1, \alpha=0.05)} \frac{s}{\sqrt{n}}$$

$$t_{(n-1, \alpha=0.05)} = t_{(35, \alpha=0.05)} = 2.03$$

$$599.194 \pm 2.03 * 3.109 = (592.8, 605.5)$$

Sono i limiti entro cui dovremmo trovare la media della popolazione ($\mu = 607$) da cui è stato tratto il campione di 36 suini e che non comprende il valore di 607: i 36 suini non provengono (probabilmente) da una popolazione con un IMPG di 607 g


CONFRONTI TRA MEDIE DI 2 CAMPIONI

Medie di 2 gruppi di osservazioni che possono essere


Indipendenti: le unità sperimentali sono assegnate casualmente a due trattamenti

Appaiati: i due trattamenti sono applicati a ciascuna unità sperimentale

Disegno a due campioni



Disegno per dati appaiati



CONFRONTI TRA MEDIE DI 2 CAMPIONI

Sono campioni indipendenti estratti da popolazioni normalmente distribuite, con media μ_1 e μ_2 , e con varianza non nota

Si valuta se le differenze osservate tra le medie di 2 campioni sono troppo grandi per essere attribuite al caso:

1) Si formula un'ipotesi nulla: nella maggior parte dei casi si testa se le medie delle 2 popolazioni sono uguali

$$H_0 : \bar{x}_1 = \bar{x}_2$$

2) Si stabilisce il livello di probabilità, soglia α

3) Si calcola la probabilità di ottenere una coppia di medie così differenti

4) Se la probabilità è più piccola di α , rifiutiamo l'ipotesi nulla

CONFRONTI TRA MEDIE DI 2 CAMPIONI

Statistica che si utilizza per il confronto di campioni indipendenti

$$t_{[gl]} = \frac{\bar{x}_1 - \bar{x}_2}{S_{\bar{x}_1 - \bar{x}_2}}$$

gl (gradi di libertà) è la somma dei gradi di libertà dei due campioni:

$$(n_1 - 1) + (n_2 - 1) = n_1 + n_2 - 2$$

S è l'errore standard della differenza tra le medie dei due campioni

$$S_{\bar{x}_1 - \bar{x}_2} = \sqrt{S^2 \frac{n_1 + n_2}{n_1 n_2}}$$

Per calcolarla è necessario calcolare la varianza ponderata

$$S^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{(n_1 - 1) + (n_2 - 1)}$$

CONFRONTI TRA MEDIE DI 2 CAMPIONI

DISTRIBUZIONE DEL T DI STUDENT (test bilaterale)

g.l.	α								
	0.5	0.4	0.2	0.1	0.05	0.025	0.01	0.005	0.001
1	1.000	1.376	3.078	6.314	12.706	25.452	63.657		
2	0.816	1.061	1.886	2.920	4.303	6.205	9.925	14.089	31.598
3	0.765	0.978	1.638	2.353	3.182	4.177	5.841	7.453	12.941
4	0.741	0.941	1.533	2.132	2.776	3.495	4.604	5.598	8.610
5	0.727	0.920	1.476	2.015	2.571	3.163	4.032	4.773	6.868
6	0.718	0.906	1.440	1.943	2.447	2.969	3.707	4.317	5.959
7	0.711	0.896	1.415	1.895	2.365	2.841	3.499	4.029	5.408
8	0.706	0.889	1.397	1.860	2.306	2.752	3.355	3.833	5.041
9	0.703	0.883	1.383	1.833	2.262	2.685	3.250	3.690	4.780
10	0.700	0.879	1.372	1.812	2.228	2.634	3.169	3.581	4.587
11	0.697	0.876	1.363	1.796	2.201	2.593	3.106	3.497	4.437
12	0.695	0.873	1.356	1.782	2.179	2.560	3.055	3.428	4.318
13	0.694	0.870	1.350	1.771	2.160	2.533	3.012	3.372	4.221
14	0.692	0.868	1.345	1.761	2.145	2.510	2.977	3.326	4.140
15	0.691	0.866	1.341	1.753	2.131	2.490	2.947	3.286	4.073
16	0.690	0.865	1.337	1.746	2.120	2.473	2.921	3.252	4.015
17	0.689	0.863	1.333	1.740	2.110	2.458	2.898	3.222	3.965
18	0.688	0.862	1.330	1.734	2.101	2.445	2.878	3.197	3.922
19	0.688	0.861	1.328	1.729	2.093	2.433	2.861	3.174	3.883
20	0.687	0.860	1.325	1.725	2.086	2.423	2.845	3.153	3.850
21	0.686	0.859	1.323	1.721	2.080	2.414	2.831	3.135	3.819
22	0.686	0.858	1.321	1.717	2.074	2.405	2.819	3.119	3.792
23	0.685	0.858	1.319	1.714	2.069	2.398	2.807	3.104	3.768
24	0.685	0.857	1.318	1.711	2.064	2.391	2.797	3.091	3.745
25	0.684	0.856	1.316	1.708	2.060	2.385	2.787	3.078	3.725
26	0.684	0.856	1.315	1.706	2.056	2.379	2.779	3.067	3.707
27	0.684	0.855	1.314	1.703	2.052	2.373	2.771	3.057	3.689
28	0.683	0.855	1.313	1.701	2.048	2.368	2.763	3.047	3.674
29	0.683	0.854	1.311	1.699	2.045	2.364	2.756	3.038	3.659
30	0.683	0.854	1.310	1.697	2.042	2.360	2.750	3.030	3.646
40	0.681	0.851	1.303	1.684	2.021	2.329	2.704	2.971	3.551
50	0.679	0.849	1.299	1.676	2.009	2.311	2.678	2.937	3.496
60	0.679	0.848	1.296	1.671	2.000	2.299	2.660	2.915	3.460
70	0.678	0.847	1.294	1.667	1.994	2.291	2.648	2.899	3.435
80	0.678	0.846	1.292	1.664	1.990	2.284	2.639	2.887	3.416
90	0.677	0.846	1.291	1.662	1.987	2.280	2.632	2.878	3.402
100	0.677	0.845	1.290	1.660	1.984	2.276	2.626	2.871	3.390

La tabella riporta:

- **In alto:** aree sotto la curva solo per alcune probabilità α
- **A sinistra:** i gradi di libertà

Esempio

Per un determinato valore di g.l., il valore della tabella rappresenta il valore di t che delimita il 5% della distribuzione (2.5% per parte)

CONFRONTI TRA MEDIE DI 2 CAMPIONI

È stato misurato il cortisolo ematico in 18 cani, 9 maschi e 9 femmine. Ci si chiede se il sesso influenza il livello di cortisolo. Sono stati ottenuti i seguenti risultati

Sesso	n	Media	s
M	9	61,59	49,04
F	9	70,29	28,36

Domanda: le medie dei 2 sessi differiscono in modo significativo? $H_0 : \bar{x}_M = \bar{x}_F$

Livello di significatività: $\alpha = 0.05$

Utilizziamo la statistica test t-student

Sesso	n	Media	s	s ²	gl
M	9	61,59	49,04	2404,92	8
F	9	70,29	28,36	804,29	8


$$\bar{S}^2 = \frac{(2404.92 * 8) + (804.29 * 8)}{(9 - 1) + (9 - 1)} = 1604.61 \quad s_{\bar{x}_1 - \bar{x}_2} = \sqrt{1604.61 \frac{9 + 9}{9 * 9}} = 18.88$$

$$t = \frac{61.59 - 70.29}{18.88} = -0.46$$

CONFRONTI TRA MEDIE DI 2 CAMPIONI

Nella figura sono riportate la distribuzione t con g.l. =16 e le due aree di rifiuto dell'ipotesi nulla, che sommate sono pari al 5%

I valori assunti da t che delimitano le due aree sono **-2.1199** e **+2.1199**. Il valore relativo alla differenza tra le medie dei sessi è pari a -0.46 e quindi compreso nella regione di accettazione di H_0



USO DELLE TAVOLE

- Si cerca il valore di t ottenuto per i g.l. in esame (16) e $\alpha = 0.05 \Rightarrow t = 2.120$
- Lo si confronta con il valore di t relativo alla differenza tra le medie $\Rightarrow 0.46$ (in valore assoluto data la simmetria della distribuzione e dal fatto che la tavola in uso riporta il valore considerato per entrambe le code sommate, test bilaterale. Cosa fare con tavola solo destra?)

Quindi:

$t_{\text{tabulato}} > t_{\text{trovato}} \Rightarrow \text{accetto } H_0$

CONFRONTI TRA MEDIE DI 2 CAMPIONI

Esercizio 1

Un commerciante verifica la durata di due diverse marche di lampadine.

Con 8 lampadine della marca A ottiene una media = 1237 ore
con $s = 36$;

con 7 lampadine della marca B ottiene una media di 1036 ore
con $s = 40$.

A fronte di tale risultato il commerciante vuole sapere se la differenza tra le due medie è tale da poter affermare con una probabilità del 95% che le lampadine di marca A hanno una durata superiore a quelle di marca B.

CONFRONTI TRA MEDIE DI 2 CAMPIONI

Esercizio 1 – Soluzione

1. Formulazione delle ipotesi:

$$H_0: \mu_a = \mu_B$$

$$H_1: \mu_a > \mu_B$$

2. Calcolo di t:
$$t_{[gl]} = \frac{\bar{x}_1 - \bar{x}_2}{s_{\bar{x}_1 - \bar{x}_2}}$$

$$n_A = 7 \quad n_B = 6 \quad s_A^2 = 1296 \quad s_B^2 = 1600 \quad \mu_A = 1237 \quad \mu_B = 1036$$

$$s_{\bar{x}_1 - \bar{x}_2} = \sqrt{\frac{(7 * 1296) + (6 * 1600)}{7 + 6} \cdot \frac{8 + 7}{8 * 7}} = \sqrt{1436.307 * 0.267} = 19.6144$$

$$t_{cal} = \frac{1237 - 1036}{19.61} = 10.25$$

CONFRONTI TRA MEDIE DI 2 CAMPIONI

Esercizio 1 – Soluzione

3. Determinare i valori critici:

Il livello di significatività richiesto è $\alpha=0.05$, ricordandosi che il test è **unidirezionale** (controllo la coda di destra), i gradi di libertà sono 13, quindi il valore critico è **$t=1.771$**

4. Decisione

Poiché $t_{\text{cal}} = 10.25$ è maggiore del valore critico $t=1.771$, dobbiamo ricettare l'ipotesi H_0 . Le lampadine della marca A sono migliori (per durata) di quelle della marca B

CONFRONTI TRA MEDIE DI 2 CAMPIONI

Confronto tra medie per dati appaiati

- Un ricercatore si chiede se il livello medio dell'ematocrito cambia negli atleti dopo che hanno svolto una attività fisica intensa
- Rileva l'ematocrito prima e dopo la gara
- Ogni individuo fornisce due osservazioni
- Ogni coppia di osservazioni (prima e dopo la gara, per ciascun individuo) ha un fattore in comune: l'individuo sulla quale è stata rilevata
- Se quindi ci sono $2n$ osservazioni, ma solo n atleti, non possiamo assumere che ci siano $2n$ osservazioni indipendenti come se fossero stati $2n$ atleti.
- Le due osservazioni sullo stesso soggetto non sono indipendenti, perché influenzate da fattori individuali comuni
- Per esempio, se un atleta ha normalmente un basso livello di ematocrito, lo avrà anche basso rispetto agli altri dopo la gara: conoscendo il primo valore posso prevedere in parte il secondo

CONFRONTI TRA MEDIE DI 2 CAMPIONI

Il test t per dati appaiati si riduce ad un semplice test t dopo aver calcolato la differenza tra le misure effettuate su ogni unità sperimentale

$$H_0 : \mu_{\bar{d}} = 0 \quad t = \frac{\bar{d}}{ES_{\bar{d}}}$$

$\bar{d}$ è la differenza media tra le osservazioni di ogni unità

$ES_{\bar{d}}$ è l'errore standard della differenza:

$$\frac{s_{\bar{d}}}{\sqrt{n}}$$

Data l'ipotesi nulla, la statistica t ha una distribuzione t con $gl = n-1$

CONFRONTI TRA MEDIE DI 2 CAMPIONI

In molte specie i maschi hanno maggiori possibilità di attrarre le femmine se presentano elevati livelli di testosterone. Un'ipotesi è che i maschi con più elevati livelli di testosterone siano più vulnerabili alle malattie. Per verificare questa ipotesi, un gruppo di ricercatori hanno aumentato sperimentalmente i livelli di testosterone di 13 maschi di merlo alirose (*Agelaius phoeniceus*), impiantando un tubicino permeabile contenente testosterone. Il livello anticorpale ($\ln[\text{mDO}/\text{min}]$) è stato misurato prima e dopo l'impianto

$$H_0 : \mu_{\bar{d}} = 0 \quad \bar{d} = -0.056$$

$$s_d^2 = 0.025(\text{varianza}) \quad s_d = 0.159(\text{deviazione standard})$$

$$ES_d = \frac{S_d}{\sqrt{n}} = \frac{0.159}{\sqrt{13}} = 0.044$$

$$t_{\bar{d}} = \frac{\bar{d}}{ES_d} = \frac{-0.056}{0.044} = -1.27 \quad t_{\alpha=0.05, gl=12} = 2.18$$

Poiché $1.27 < 2.18$, accetto H_0 : il testosterone non ha effetto sull'immunocompetenza dei maschi

ID Maschio	Produzione anticorpi PRIMA	Produzione anticorpi DOPO	d
1	4.65	4.44	0.21
4	3.91	4.30	-0.39
5	4.91	4.98	-0.07
6	4.50	4.45	0.05
9	4.80	5.00	-0.20
10	4.88	5.00	-0.12
15	4.88	5.01	-0.13
16	4.78	4.96	-0.18
17	4.98	5.02	-0.04
19	4.87	4.73	0.14
20	4.75	4.77	-0.02
23	4.70	4.60	0.10
24	4.93	5.01	-0.08



Da: Analisi statistica dei dati biologici (2010), Ed. Zanichelli

CONFRONTI TRA MEDIE DI 2 CAMPIONI

Esercizio

La tabella mostra la pressione sistolica misurata ad 11 pazienti ipertesi dopo la somministrazione di placebo e di idroclorotiazide.

In base ai risultati osservati, vi è una qualsiasi evidenza di una differenza nella pressione media sistolica sanguigna a seguito di questi due trattamenti?

Paziente	Placebo	Idroclorot.	differenze
1	211	181	30
2	210	172	38
3	210	196	14
4	203	191	12
5	196	167	29
6	190	161	29
7	191	178	13
8	177	160	17
9	173	149	24
10	170	119	51
11	163	156	7

CONFRONTI TRA MEDIE DI 2 CAMPIONI

Esercizio - soluzione

1. Formulazione delle ipotesi

$H_0 : \mu_{\bar{d}} = 0$, la media delle differenze è 0

$H_0 : \mu_{\bar{d}} \neq 0$, la media delle differenze è diversa da 0

2. Calcolo del valore t

$$\bar{s} = \frac{\sum d_i}{n} = \frac{264}{11} = 24.0$$

$$s_d = \sqrt{\frac{\sum (d_i - \bar{d})^2}{n - 1}} = \sqrt{\frac{(30.34)^2 + \dots + (7 - 24)^2}{10}} = 13.09$$

$$t_{cal} = \frac{\bar{d}}{ES_{\bar{d}}} = \frac{\bar{d}}{\frac{s_d}{\sqrt{n}}} = \frac{24}{\frac{13.09}{\sqrt{11}}} = 6.08$$

CONFRONTI TRA MEDIE DI 2 CAMPIONI

Esercizio - soluzione

3. Determinazione dei valori critici

Assumiamo un livello di significatività di $\alpha=0.05$, i gradi di libertà sono 10, quindi il valore critico è $t=2.228$ (stavolta verifichiamo su una tabella unilaterale, cercando la significatività, destra o sinistra, dello 0.025)

4. Decisione

Poiché $t_{cal} = 6.08$ è maggiore del valore critico $t = 2.228$ dobbiamo rigettare l'ipotesi H_0

La pressione dei pazienti a cui è stato somministrato idroclorotiazide è statisticamente diversa dalla pressione dei pazienti a cui è stato somministrato il placebo