



UNIVERSITÀ DEGLI STUDI
DI MILANO


INFORMATICA E BIOSTATISTICA

Anno Accademico 2024-2025




RELAZIONE TRA VARIABILI CONTINUE

CORRELAZIONE REGRESSIONE



RELAZIONE TRA VARIABILI CONTINUE

Per visualizzare la variazione simultanea di 2 variabili (o associazione) si utilizza il **grafico a dispersione** o **scatter plot**



Dal grafico si nota che:

All'aumento dell'altezza al garrese corrisponde l'aumento del perimetro toracico

Ci sono osservazioni che presentano valori estremi delle 2 variabili

COVARIANZA

Misura la variabilità congiunta di 2 variabili continue (x e y)

Se si considerano due variabili misurate sulla stessa i^{esima} osservazione, la covarianza è:

$$S_{xy} = Cov_{xy} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

Il numeratore si chiama **CODEVIANZA**

La covarianza può essere di segno positivo o negativo

COVARIANZA

VARIANZA

$$s^2 = \frac{\sum (x - \bar{x})^2}{n - 1}$$

$$s^2 = \frac{\sum x^2 - \frac{(\sum x)^2}{n}}{n - 1}$$

Numeratore **DEVIANZA**

COVARIANZA

$$S_{xy} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

$$S_{xy} = \frac{\sum xy - \frac{\sum x \sum y}{n}}{n - 1}$$

Numeratore **CODEVIANZA**

COVARIANZA

Calcolo della covarianza

$$S_{xy} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

Esempio:

x	y	m _x	m _y	x - m _x	y - m _y	(x - m _x)*(y - m _y)
13	2	12	3	1	-1	-1
15	6	12	3	3	3	9
10	1	12	3	-2	-2	4
12	3	12	3	0	0	0
8	0	12	3	-4	-3	12
14	6	12	3	2	3	6
72	18	72	18	0	0	30

30 = Codevianza

30/5 = 6 = Covarianza

COVARIANZA

Esempio :

i	x	y	$x_i y_i$
1	13	2	26
2	15	6	90
3	10	1	10
4	12	3	36
5	8	0	0
6	14	6	84
Totale	72	18	246

$$Cov_{xy} = \frac{\sum xy - \frac{\sum x \sum y}{n}}{n - 1}$$

$$Cov(x, y) = \frac{246 - \frac{72 \cdot 18}{6}}{5} = 6$$

CORRELAZIONE

- Simbolo r
- Misura adimensionale dell'associazione tra due variabili (x e y)
- Formula

$$r_{xy} = \frac{Cov(x, y)}{\sqrt{s^2(x)s^2(y)}}$$

Esempio precedente:

$$r = \frac{6}{\sqrt{6.8 * 6.4}} = 0.9095$$

ρ = coefficiente di correlazione della popolazione

r = coefficiente di correlazione del campione

Il coefficiente di correlazione può essere negativo o positivo

Il segno positivo o negativo dipende dalla covarianza


CORRELAZIONE

Limiti del coefficiente di correlazione

+1 ► associazione perfetta positiva

- 1 ► associazione perfetta negativa

0 ► assenza di associazione (covarianza = 0)



Il coefficiente di correlazione varia da -1 (associazione perfetta negativa) a +1 (associazione perfetta positiva)

Se la correlazione è perfetta, ossia se $r = -1$ o $r = +1$, i punti giacciono su una linea

$0 < r < 0,3$ correlazione debole
 $0.3 < r < 0.7$ correlazione moderata
 $r > 0.7$ correlazione forte.

CORRELAZIONE

Analisi della correlazione

$H_0: r_{xy}=0$ ► assenza di correlazione

1) Si calcola la statistica t (distribuzione t di student)

$$t = r \sqrt{\frac{n-2}{1-r^2}}$$

2) Dove :

r = coefficiente di correlazione

$n-2$ = GL (2 GL in meno perché bisogna stimare sia $\bar{x}$ che $\bar{y}$)

$$t = r \sqrt{\frac{n-2}{1-r^2}} \text{ deriva da } t = \frac{r}{ES_r} \text{ con } ES_r = \sqrt{\frac{1-r^2}{n-2}}$$


3) Si confronta il t ottenuto con la distribuzione teorica t_{n-2}

CORRELAZIONE

Esempio: Sono stati raccolti i coefficienti di consanguineità (F) di 24 figliate di lupi e il numero di cuccioli di ciascuna figliata sopravvissuti al primo inverno.

Il N° di cuccioli sopravvissuti al primo inverno è correlato al coefficiente di consanguineità?

F	cuccioli
0	6
0	6
0.13	7
0.13	5
0.13	4
0.19	8
0.19	7
0.19	4
0.22	4
0.24	3
0.24	3
0.24	3
0.24	3
0.24	2
0.24	2
0.25	6
0.27	3
0.3	5
0.3	3
0.3	2
0.3	1
0.36	3
0.37	2
0.4	3



x = coefficiente di consanguineità

y = N° cuccioli

$$s_x^2 = 0.099$$

$$s_y^2 = 3.52$$

$$COV_{xy} = -0.11357$$

CORRELAZIONE

Esempio:

$H_0: \rho = 0$

$$r = \frac{-0.11357}{\sqrt{0.0099 * 3.52}} = -0.608$$

$$t = r \sqrt{\frac{n-2}{1-r^2}} = -0.608 \sqrt{\frac{24-2}{1-(-0.608)^2}} = -3.59$$

Valore tabulato per GL = 24-2 = 22: $t_{22, 0.05} = 2.704$

Il valore trovato $3.59 > 2.704$

RIFIUTO H_0 : il coefficiente di consanguineità è quindi correlato negativamente al numero di cuccioli sopravvissuti

CORRELAZIONE

Esercizio 1

Si vuole studiare la relazione che intercorre tra la temperatura e il tempo (in minuti) di sopravvivenza di certi micro-organismi. Si sono rilevati i seguenti dati:

Temperatura	Tempo di sopravvivenza
20	10
24	12
28	18
30	24
32	22
36	20

Calcolare il coefficiente di correlazione r e commentare il risultato.

CORRELAZIONE

Esercizio 1 – Soluzione

Indichiamo con X le temperature e con Y il tempo di sopravvivenza

Partiamo dalle medie di X e Y:

$$\bar{x} = \frac{\sum_i x_i}{6} = \frac{170}{6} = 28.33 \quad \bar{y} = \frac{\sum_i y_i}{6} = \frac{106}{6} = 17.67$$

Per calcolare il coefficiente di correlazione è utile compilare la seguente tabella:

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	y_i	$y_i - \bar{y}$	$(y_i - \bar{y})^2$	$x_i \cdot y_i$
20	-8,33	69,44	10	-7,67	58,83	200
24	-4,33	18,75	12	-5,67	32,15	288
28	-0,33	0,11	18	0,33	0,11	504
30	1,67	2,79	24	6,33	40,07	720
32	3,67	13,45	22	4,33	18,75	704
36	7,67	58,83	20	2,33	5,43	720
TOT.		163,37			155,34	3136

CORRELAZIONE

Esercizio 1 – Soluzione

Ora possiamo calcolare il coefficiente di correlazione r:

$$r_{xy} = \frac{Cov(x, y)}{\sqrt{s^2(x)s^2(y)}}$$

$$\begin{aligned} r_{xy} &= \frac{\frac{\sum (x - \bar{x})(y - \bar{y})}{n-1}}{\sqrt{\frac{\sum (x - \bar{x})^2}{n-1} \cdot \frac{\sum (y - \bar{y})^2}{n-1}}} \\ &= \frac{\frac{63.89 + 24.550.11 + 10.57 + 15.89 + 17.87}{5}}{\sqrt{\frac{163.37}{5} \cdot \frac{155.34}{5}}} = \frac{\frac{132.66}{5}}{\frac{159.3}{5}} \\ &= \frac{132.66}{159.3} \simeq 0.83 \end{aligned}$$

Il coefficiente indica una forte correlazione diretta tra temperatura e tempo di sopravvivenza

CORRELAZIONE

Esercizio 1 – Soluzione

Pensiamo all'ipotesi nulla

$$H_0 : r_{(x,y)} = 0 \quad \alpha = 0.05 \rightarrow t_{(gl=4, \alpha=0.05)} = 2.776$$

$$t = 0.83 \frac{\sqrt{4}}{\sqrt{1 - (0.83)^2}} = 0.83 \frac{2}{\sqrt{0.3111}} = 2.97$$

Il t calcolato è maggiore del t teorico ($2.97 > 2.776$), per cui l'ipotesi nulla è rifiutata

La correlazione non è infondata

MATRICE DI VARIANZA E COVARIANZA

Per analizzare l'associazione di 3 o più variabili, i dati possono essere sintetizzati in tabelle a 2 entrate di n righe x n colonne, dove n è il numero di variabili → MATRICE (tabella speculare rispetto alla diagonale)

MATRICE DI VARIANZE E COVARIANZE

- Sulla diagonale si pongono le varianze
- Nei triangoli superiore e inferiore si pongono le covarianze

Esempio:

3 parametri del sangue rilevati in 40 gatti

1) Fosforo P 2) Calcio CA 3) Carbonato HCO₃

MATRICE DI VARIANZE E COVARIANZE			
	P	CA	HCO ₃
P	4.692	-0.077	-0.925
CA	-0.077	0.003	0.013
HCO ₃	-0.925	0.013	0.621

MATRICE DI CORRELAZIONE

MATRICE DI CORRELAZIONE

- Nelle caselle si pongono i coefficienti di correlazione con relativa probabilità
- Sulla diagonale $r = 1$ (correlazione di ciascuna variabile con sé stessa)

Esempio:

3 parametri del sangue rilevati in 40 gatti

1) Fosforo P 2) Calcio CA 3) Carbonato HCO₃

MATRICE DI CORRELAZIONE			
	P	CA	HCO ₃
P	1	-0.60539 <0.0001	-0.54173 0.0003
CA	-0.60539 <0.0001	1	0.2752 0.0857
HCO ₃	-0.54173 0.0003	0.2752 0.0857	1

In rosso r

In blu $P(H_0: r = 0)$