



UNIVERSITÀ DEGLI STUDI
DI MILANO

INFORMATICA E BIOSTATISTICA

Anno Accademico 2024-2025




CORRELAZIONE E REGRESSIONE

RELAZIONI TRA VARIABILI CONTINUE

CORRELAZIONE

REGRESSIONE



REGRESSIONE

Misura la dipendenza di una variabile, la y (= variabile dipendente), dall'altra, la x (=variabile indipendente, o covariata)

Simbolo: **b**

Formula:

$$b = \frac{Cov(x, y)}{var(x)}$$


E' quindi espressa in unità di misura della y (variabile dipendente)

Misura quanto varia la y al variare di un'unità della x

REGRESSIONE

Esempio:

i	x	y	x^2	$x_i y_i$
1	13	2	169	26
2	15	6	225	90
3	10	1	100	10
4	12	3	144	36
5	8	0	64	0
6	14	6	196	84
Totale	72	18	898	246



Si considerano 2 variabili , x e y, relative a 6 osservazioni e si riportano i dati in un grafico a dispersione

Grafico a dispersione dei dati riportati in tabella

REGRESSIONE

Esempio:

i	x	y	x ²	x _i y _i
1	13	2	169	26
2	15	6	225	90
3	10	1	100	10
4	12	3	144	36
5	8	0	64	0
6	14	6	196	84
Totale	72	18	898	246

$$v(x) = \frac{898 - \frac{72^2}{6}}{5} = 6.8$$

$$Cov(x, y) = \frac{246 - \frac{72 \cdot 18}{6}}{5} = 6$$



$$b_{xy} = \frac{Cov(x, y)}{v(x)} = \frac{6}{6.8} = 0.8823$$

REGRESSIONE

Lo scatter plot (o diagramma di dispersione) descrive la relazione tra le 2 variabili X e Y

Come si può prevedere una variabile in base all'altra?

Tracciando una retta





Ma...

Si possono tracciare molte rette

REGRESSIONE

La retta migliore è quella che minimizza gli scarti tra i punti dei dati (valori osservati) e i punti sulla retta (valori attesi)

LA **RETTA** PER LA QUALE SIA MINIMA LA SOMMA DI TUTTI I QUADRATI DEGLI SCARTI:



REGRESSIONE

La retta è descritta matematicamente dalla seguente equazione:

$$y = a + bx \quad \text{dove} \quad b = \frac{Cov(x, y)}{v(x)} \quad a = \bar{x} - b\bar{y}$$

a = costante = intercetta: esprime il valore di y (ordinata) quando x è uguale a 0

b: esprime la pendenza della retta di regressione ossia la variazione di y quando x varia di un'unità:

- **b di segno positivo**: retta sale verso destra (le due variabili sono associate positivamente)
- **b di segno negativo**: retta scende verso destra (le due variabili sono associate negativamente)
- **b uguale a zero**: retta è orizzontale, parallela all'asse delle x (non c'è variazione congiunta)


REGRESSIONE

$$b = \frac{Cov(x, y)}{v(x)} = \frac{6}{6.8} = 0.88$$

$$\bar{y} = \frac{18}{6} = 3$$

$$\bar{x} = \frac{72}{6} = 12$$

$$a = 3 - (0.88 * 12) = -7.59$$



La retta che descrive i dati è:

$$y = -7.59 + 0.8823x$$

Con questa equazione si può calcolare il valore atteso di y dato un valore di x →
retta di previsione

REGRESSIONE

Modello statistico di regressione lineare semplice :

$$y_i = a + bx_i + e_i$$

Qualsiasi i -ma osservazione (y_i) è funzione (= il risultato) di

- 1) una costante (a)
- 2) un coefficiente di regressione (b) che moltiplica il corrispondente i -mo valore di x (x_i)
- 3) un ulteriore effetto casuale detto errore (e_i)

Il modello di regressione (come ogni altro modello) è uno **strumento di previsione**.

Per ciascuna osservazione, y_i , si può calcolare:

(1) Valore atteso $E(y_i)$

(2) Scostamento e_i

$$y_i = a + bx_i + e_i$$

$$y_i = E(y_i) + e_i$$

$$E(y_i) = a + bx_i$$

$$e_i = y_i - E(y_i)$$

REGRESSIONE

Data l'equazione: $y = a + b(x)$:

$a = \bar{y} - b(\bar{x})$ INTERCETTA

$$\bar{y} = \frac{18}{6} = 3$$

$$\bar{x} = \frac{72}{6} = 12$$

$$b = 0.88$$

$$a = \bar{y} - b(\bar{x}) = 3 - (0.88) * (12) = -7.69 \text{ INTERCETTA}$$

$$y = -7.59 + 0.88x \rightarrow \text{Valore atteso} = E(y)$$

i	y_i	x_i	$E(y_i)$	e_i
1	2	13	3.85 (-7.59+0.88*13)	-1.85 (2 - 3.85)
2	6	15	5.61 (-7.59+0.88*15)	0.39 (6-5.61)
3	1	10	1.21 (-7.59+0.88*10)	-0.21 (1 - 1.21)
4	3	12	2.97 (-7.59+0.88*12)	0.03 (3 - 2.97)
5	0	8	-0.55 (-7.59+0.88*8)	0.55 (0-(-0.55))
6	6	14	4.73 (-7.59+0.88*14)	1.27 (6 - 4.73)

REGRESSIONE

Sono riportati i pesi e le età di agnelli di razza Bergamasca. Calcolare il peso di un agnello a 17 mesi di età

X	Y
Età (mesi)	Peso (kg)
1	6
2	22
3	22
4	35
5	41
6	47
7	56
8	59
9	64
10	68
11	72
12	79
13	80
14	86
15	92

$$\bar{x} = 8$$

$$\bar{y} = 55.27$$

$$Var(x) = 20$$

$$Var(y) = 666.067$$

$$b = \frac{Cov(x, y)}{Var(x)} = 5.69$$

$$a = \bar{y} - b\bar{x} = 55.27 - 5.69 * 8 = 9.69$$


Equazione di previsione:

$$Y(\text{peso}) = 9.69 + 5.69 * x (\text{età})$$

$$\text{Peso previsto a 17 mesi} = 9.69 + 5.69 * 17 = 106.5 \text{ kg}$$

REGRESSIONE

x (età)	E(y)	y
	ATTESO	OSSERVATO
1	15.39	6
2	21.09	22
3	26.78	22
4	32.48	35
5	38.18	41
6	43.87	47
7	49.57	56
8	55.27	59
9	60.96	64
10	66.66	68
11	72.36	72
12	78.05	79
13	83.75	80
14	89.45	86
15	95.14	92



Per tracciare la retta sono sufficienti 2 punti

REGRESSIONE

Esercizio 1

Si vuole studiare la relazione che intercorre tra la temperatura e il tempo (in minuti) di sopravvivenza di certi micro-organismi. Si sono rilevati i seguenti dati:

Temperatura	Tempo di sopravvivenza
20	10
24	12
28	18
30	24
32	22
36	20

1. Determinare l'equazione della retta dei minimi quadrati.
2. Determinare la temperatura per cui un micro-organismo sopravvive per 15 minuti.

REGRESSIONE

Esercizio 1 - Soluzione

Nella scorsa lezione avevamo già calcolato una serie di parametri che ci interessano:

$$r = 0.83$$

$$\bar{x} = 28.33$$

$$\bar{y} = 17.67$$

$$Cov(x, y) = 132.66$$

Varianza non divisa
per semplificazione
con covarianza

$$Var(x) = 163.37 \quad Var(y) = 155.34$$

L'equazione della retta dei minimi quadrati $y = a + bx$ ($x = temperatura$, $y = tempo$)


$$b = \frac{Cov(x, y)}{Var(x)} = \frac{132.66}{163.37} = 0.812$$

$$a = \bar{y} - b\bar{x} = 17.67 - 0.812 * 28.33 = -5.34$$

Quindi l'equazione della retta è: $y = -5.34 + 0.812x$

REGRESSIONE

Esercizio 1 - Soluzione



REGRESSIONE

Esercizio 1 - Soluzione


2. Poniamo $y = 15\text{min}$, allora la temperatura per cui il microorganismo sopravvive è data da:

$$y = -5.34 + 0.812x$$

$$x = \frac{y + 5.34}{0.812} = \frac{15 + 5.34}{0.812} = 25.05^{\circ}\text{C}$$

REGRESSIONE

Esercizio 1 – Soluzione alternativa



REGRESSIONE

Esercizio 1 – Soluzione alternativa

L'equazione della retta dei minimi quadrati $y = a + bx$ ($y = \text{temperatura}$, $x = \text{tempo}$)

$$b = \frac{132.66}{155.34} = 0.854$$

$$a = 28.33 - 0.854 * 17.67 = 13.239$$

Quindi l'equazione della retta è: $y = 13.239 + 0.854x$

Per $x = 15$

$$13.239 + 0.854 * 15 = 26.049$$

REGRESSIONE

Esercizio 2

In tabella sono riportati i punteggi (in centesimi) ottenuti da 10 studenti in due esami di Matematica:

1. Calcolare il coefficiente di correlazione r e commentare il risultato.
2. Determinare l'equazione della retta dei minimi quadrati.
3. Che punteggio dovrebbe ottenere in Matematica I uno studente che ha preso 72 in Matematica II?

Matematica I	Matematica II
51	74
68	70
97	93
55	67
95	99
74	73
20	33
91	91
74	80
80	86

REGRESSIONE

Esercizio 2 – soluzione

Matematica I: x

Matematica II: y

$$\bar{x} = \frac{\sum_i x_i}{10} = \frac{705}{10} = 70.5 \quad \bar{y} = \frac{\sum_i y_i}{10} = \frac{766}{10} = 76.6$$

$$Var(x) = \frac{\sum_i (x_i - \bar{x})^2}{9} = \frac{5014.5}{9} = 557.167$$

$$Var(y) = \frac{\sum_i (y_i - \bar{y})^2}{9} = \frac{3134.4}{9} = 348.267$$

$$Covar(x, y) = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{9} = \frac{3785}{9} = 420.556$$

REGRESSIONE

Esercizio 2 – soluzione

Matematica I: x

Matematica II: y

$$b = \frac{Cov(x, y)}{Var(x)} = \frac{420.556}{555.167} = 0.755$$

$$a = \bar{y} - b\bar{x} = 76.6 - (0.755 * 70.5) = 23.386$$

$$y = a + bx = 23.386 + 0.755 * x$$

Se uno studente ha preso 72 in Matematica II allora dovrebbe prendere in Matematica I:

$$x = \frac{y - 23.386}{0.755} = \frac{72 - 23.386}{0.755} = 64.41$$

REGRESSIONE

Esercizio 2 – soluzione alternativa

Matematica I: y

Matematica II: x

$$b = \frac{420,556}{348.267} = 1.208$$

$$a = 70.5 - 1.208 * 76.6 = -22.0328$$

$$y = -22.03285 + 1,208 * x$$

Se uno studente ha preso 72 in Matematica II allora dovrebbe prendere in Matematica I:

$$x = -22.03285 + 1,208 * 72 = 64.943$$