



UNIVERSITÀ DEGLI STUDI
DI MILANO

INFORMATICA E BIOSTATISTICA

Anno Accademico 2024-2025



TEST CHI-QUADRO

La misura χ^2 misura la discrepanza esistente tra le frequenze osservate e quelle teoriche (attese) su una serie di dati:

$$\chi^2 = \frac{(\text{frequenze osservate} - \text{frequenze attese})^2}{\text{frequenze attese}}$$

I test chi quadrato è utilizzato per verificare che le frequenze dei valori osservati si adattino alle frequenze teoriche di una distribuzione di probabilità prefissata.

TEST CHI-QUADRO

- Se le frequenze osservate coincidono con quelle attese, X^2
 - Più grande è la discrepanza tra le frequenze osservate e quelle attese, più è grande il valore di X^2
 - Le frequenze sono sempre frequenze assolute (non frequenze relative o percentuali)
 - Le percentuali vanno sempre ritrasformate in frequenze assolute moltiplicandole per il numero di osservazioni
- In generale:** quando si è interessati a stabilire se alcune serie di dati
- Seguono una distribuzione teorica (normale, binomiale, Poisson)
 - Seguono una distribuzione attesa determinata da circostanze biologiche/statistiche

Si usa il test Chi Quadro

TEST CHI-QUADRO

La variabile test χ^2 si ottiene sommando per ogni evento (o classe o categoria) i il quadrato della differenza tra frequenze **osservate** o_i e **attese** a_i diviso la frequenza **attesa** a_i

$$\chi^2 = \sum_{i=1}^k \frac{(o_i - a_i)^2}{a_i}$$

Questa variabile test si distribuisce come una variabile χ^2 con $(k - 1)$ **gradi di libertà**

TEST CHI-QUADRO

Il valore di χ^2 ottenuto dai dati sperimentali è quindi associato ai gradi di libertà:

1) Se non si stima alcun parametro:

$$2) gl = N^{\circ} \text{ classi eventi} - 1$$

3) Se stimiamo alcuni parametri dei dati

$$4) gl = N^{\circ} \text{ classi eventi} - 1 - N^{\circ} \text{ parametri stimati dal campione}$$

Si confronta con i valori di χ^2 tabulati per quei gradi di libertà

H_0 : frequenze osservate = frequenze attese

$\chi^2 >$ del valore tabulato di χ^2



RIFIUTO H_0

$\chi^2 <$ del valore tabulato di χ^2

ACCETTO H_0

DISIBUZIONE DEL χ^2

- È una famiglia di distribuzioni in funzione dei gradi di libertà
- La variabile χ^2 può assumere solo valori positivi $(0, +\infty)$
- E' una distribuzione continua fortemente asimmetrica. L'asimmetria diminuisce all'aumentare del numero di scarti indipendenti al num



- Più marcata è la differenza dai valori attesi specificati dall'ipotesi nulla, maggiore è il valore di χ^2
- Per calcolare P nel test chi-quadro usiamo solo la coda a destra della distribuzione χ^2

DISIBUZIONE DEL χ^2

Tabella di χ^2 , selezione di valori rappresentativi per gradi di libertà da 1 a 10 (area di probabilità da χ^2 a ∞).

P g.l.	0.90	0.70	0.50	0.40	0.30	0.20	0.10	0.05	0.01	0.001
1	0.02	0.15	0.45	0.71	1.07	1.64	2.71	3.84	6.63	10.83
2	0.21	0.71	1.39	1.83	2.41	3.22	4.61	5.99	9.21	13.82
3	0.58	1.42	2.37	2.95	3.66	4.64	6.25	7.81	11.34	16.27
4	1.06	2.19	3.36	4.04	4.88	5.99	7.78	9.49	13.28	18.47
5	1.61	3.00	4.35	5.13	6.06	7.29	9.24	11.07	15.09	20.52
6	2.20	3.83	5.35	6.21	7.23	8.56	10.64	12.59	16.81	22.46
7	2.83	4.67	6.35	7.28	8.38	9.80	12.02	14.07	18.48	24.32
8	3.49	5.53	7.34	8.35	9.52	11.03	13.36	15.51	20.09	26.12
9	4.17	6.39	8.34	9.41	10.66	12.24	14.68	16.92	21.67	27.88
10	4.87	7.27	9.34	10.47	11.78	13.44	15.99	18.31	23.21	29.59

→
si rifiuta ipotesi nulla

ESERCIZIO

In una classe ci sono 34 maschi e 65 femmine.

Il rapporto sessi osservato è 1:1?

H_0 : non c'è differenza tra il campione (=studenti della classe) e la popolazione ossia il rapporto sessi nel campione è 1:1 come nella popolazione

H_0 : per i due sessi le frequenze osservate sono uguali a quelle attese sulla base del rapporto 1:1

1) Calcolo le frequenze assolute nel campione di 99 soggetti ($34 + 65$)

2) 1:1 ► 50% maschi 50% femmine

3) Maschi = $99 * 0.5 = 49.5$

Femmine = $99 * 0.5 = 49.5$

Categoria	Freq. osservate	Frequenze attese
Maschi	34	49.5
Femmine	65	49.5
Totale	99	99

ESERCIZIO

2) Calcolo χ^2 per ciascuna categoria

3) Maschi:

$$\chi^2 = \frac{(34 - 49.5)^2}{49.5} = 4.8535$$

4) Femmine:

$$\chi^2 = \frac{(65 - 49.5)^2}{49.5} = 4.8535$$

5) Calcolo χ^2 totale

$$\chi^2 = \frac{(34 - 49.5)^2}{49.5} + \frac{(65 - 49.5)^2}{49.5} = 9.707$$

ESERCIZIO

Categoria	Frequenze osservate	Frequenze attese	χ^2
Maschi	34	49.5	4.8535
Femmine	65	49.5	4.8535
Totale	99	99	9.707

4) Verifica sulle tavole

$gl = 2 - 1 = 1$ ► solo due classi, maschi e femmine

Valore χ^2 per $\alpha=0.05$, $gl = 1$ ► $3.84 < 9.707$ ► devo rifiutare l'ipotesi

P \ g.l.	0.90	0.70	0.50	0.40	0.30	0.20	0.10	0.05	0.01	0.001
1	0.02	0.15	0.45	0.71	1.07	1.64	2.71	3.84	6.63	10.83
2	0.21	0.71	1.39	1.83	2.41	3.22	4.61	5.99	9.21	13.82
3	0.58	1.42	2.37	2.95	3.66	4.64	6.25	7.81	11.34	16.27

ESERCIZIO

5) Conclusione

- 6) χ^2 altamente significativo: la probabilità che l'ipotesi nulla sia vera è inferiore allo 0.2%, ovvero: la probabilità di sbagliare rifiutando l'ipotesi nulla (errore di I tipo) è inferiore allo 0.2%
- 7) **QUINDI** ► rifiuto l'ipotesi nulla: Il rapporto sessi nella classe è significativamente diverso dal rapporto di 1:1 (50% maschi, 50% femmine).

GL CON PARAMETRI STIMATI

Nella specie umana il fatto di generare un maschio è indipendente dalla probabilità che anche il successivo sia maschio. Ci si attende che il N° di maschi e il numero di femmine in una famiglia con 2 figli segua una distribuzione binomiale. In un'indagine su 2444 famiglie sono stati trovati i risultati riportati. Si adattano ad una distribuzione binomiale?

N° maschi	N° famiglie (con 2 figli)
0	530
1	1332
2	582
Totale	2444

Non si dispone della P del sesso maschile e sesso femminile ► lo stimo (n° maschi/totale figli)

$$p = p(\text{maschio}) = 2496/4888 = 0.5106, \quad q = p(\text{femmina}) = 1 - p = 0.4894$$

Sulla base di una distribuzione binomiale si calcola la P di avere famiglie con rispettivamente 0, 1 e 2 figli maschi

GL CON PARAMETRI STIMATI

$$p(0M, n = 2) = \frac{2!}{0!(2-0)!} * 0.5106^0 * 0.4894^2 = 0.2395$$

$$p(1M, n = 2) = \frac{2!}{1!(2-1)!} * 0.5106^1 * 0.4894^1 = 0.4997$$

$$p(2M, n = 2) = \frac{2!}{2!(2-2)!} * 0.5106^2 * 0.4894^0 = 0.2607$$

GL CON PARAMETRI STIMATI

H_0 : i dati osservati sono uguali ai dati attesi in base alla distribuzione binomiale

N° maschi	N° famiglie(con 2 figli) OSSERVATE	N° famiglie(con 2 figli) ATTESE	χ^2
0	530	$(0.2395 * 2444) = 585.3$	5.237
1	1332	$(0.4997 * 2444) = 1221.4$	10.005
2	582	$(0.2607 * 2444) = 637.3$	4.779
Totale	2444	2444	20.021

$GL = 3 - 1 - 1 = 1$ (ho approssimato p per la binomiale)

Valore di χ^2 tabulato per 1 gl e $\alpha = 0.05 \blacktriangleright 3.84$

Inferiore a quello trovato (=20.021)

	Valori di α										
G.L.	0.9	0.7	0.6	0.5	0.4	0.3	0.2	0.1	0.05	0.01	0.001
1	0.02	0.15	0.27	0.45	0.71	1.07	1.64	2.71	3.84	6.63	10.83
2	0.21	0.71	1.02	1.39	1.83	2.41	3.22	4.61	5.99	9.21	13.82

Rifiuto H_0 : i dati non si distribuiscono secondo una distribuzione binomiale

ESERCIZIO

I dati si accordano con le frequenze attese in base a leggi della genetica (es. Mendel)?

La progenie di bovini Shorthorn è classificata secondo il colore del mantello: 82 rossi (RR), 209 roani (RB) e 89 bianchi (BB). Questa distribuzione si adatta con l'ipotesi che il colore del mantello sia determinato da 2 alleli codominanti?

In base all'ipotesi di codominanza, il rapporto tra i mantelli dovrebbe essere 1 rosso: 2 roani : 1 bianco.

H_0 : i dati osservati sono uguali ai dati attesi in base all'ipotesi di codominanza

Mantelli	Freq. Oss.	Freq. Attese	χ^2
Rosso	82	$380 \cdot 0.25 = 95$	$\frac{(82-95)^2}{95} = 1.78$
Roano	209	$380 \cdot 0.50 = 190$	$\frac{(209-190)^2}{190} = 1.90$
Bianco	89	$380 \cdot 0.25 = 95$	$\frac{(89-95)^2}{95} = 0.38$
Totale	380	380	4.06

ESERCIZIO

$$Gf = 3 - 1 = 2$$

Calcolare il valore χ^2 per 2 gl e $\alpha=0.05 \blacktriangleright 5.99$

Il valore teorico è superiore al valore calcolato $4.06 < 5.99$

Quindi non siamo nella coda di rigetto, non posso rifiutare l'ipotesi nulla

Accetto H_0 : i mantelli osservati nei bovini si accordano con l'ipotesi che siano controllati geneticamente da 2 alleli codominanti

ESERCIZIO

Esercizio 1

Si lanciano 200 volte 3 monete e per il lato testa si osservano le seguenti frequenze:

teste	0	1	2	3
freq.	20	63	84	35

Si ha il sospetto che le monete siano truccate; verificare questa ipotesi ad un livello di significatività del 5%.

ESERCIZIO

Esercizio 1 - soluzione

H_0 : le monete sono tutte bilanciate, quindi i risultati di testa (esito positivo) si dovrebbero distribuire secondo una distribuzione binomiale con $p = 0.5$

Lanciando 3 monete le probabilità di ottenere X teste sono:

$$p(0) = 1\left(\frac{1}{2}\right)^0\left(\frac{1}{2}\right)^3 = 0.125 \rightarrow f_0 = 0.125 * 200 = 25$$

$$p(1) = 3\left(\frac{1}{2}\right)^1\left(\frac{1}{2}\right)^2 = 0.375 \rightarrow f_0 = 0.375 * 200 = 75$$

$$p(2) = 3\left(\frac{1}{2}\right)^2\left(\frac{1}{2}\right)^1 = 0.375 \rightarrow f_0 = 0.375 * 200 = 75$$

$$p(3) = 1\left(\frac{1}{2}\right)^3\left(\frac{1}{2}\right)^0 = 0.125 \rightarrow f_0 = 0.125 * 200 = 25$$

ESERCIZIO

Esercizio 1 - soluzione

Calcoliamo gli scarti χ^2 considerando le frequenze calcolate e attese:

$$\chi^2 = \frac{(20 - 25)^2}{25} + \frac{(63 - 75)^2}{75} + \frac{(84 - 75)^2}{75} + \frac{(35 - 25)^2}{25} = 8$$

I gradi di libertà sono $\nu = 4 - 1 = 3$.

Il valore critico sulla tabella del χ^2 per $\alpha = 0.05 \blacktriangleright 7.81$

Siccome $8 > 7.81$ non possiamo accettare l'ipotesi nulla H_0

Possiamo dire, con una confidenza pari al 95%, che le monete sono truccate

ESERCIZIO

Esercizio 2

Da un campione di $n=100$ individui di una popolazione si osservano le seguenti frequenze per classi di età:

classe	freq.
5 <	8
5-10	10
10-15	23
15-20	30
20-25	18
>25	11

Valutare con significatività al 5% se si tratta di una distribuzione normale.

H_0 : il campione ha una distribuzione simile alla normale.

P.S. non notate nulla di strano in questa tabella?

ESERCIZIO

Esercizio 2 - soluzione


Usando i valori centrali di ogni classe, 2.5 per la classe più bassa e 27.5 per la classe più alta possiamo calcolare la media che vale $\mu = 16.15$ e la deviazione standard $\sigma = 6.88$

A questo punto possiamo calcolare i valori della variabile normale standardizzata $z = (x - \mu) / \sigma$ per i confini di ciascuna classe ed otteniamo:

<i>classe</i>	<i>f.emp.</i>	z_{min}	z_{max}	<i>prob</i>	<i>f.teo.</i>
5 <	8		-1,61905	0,0526	5,26
5-10	10	-1,61905	-0,89302	0,1333	13,33
10-15	23	-0,89302	-0,16699	0,2478	24,78
15-20	30	-0,16699	0,55904	0,2782	27,82
20-25	18	0,55904	1,28507	0,1887	18,87
> 25	11	1,28507		0,0994	9,94


ESERCIZIO

Esercizio 2 - soluzione



ESERCIZIO

Esercizio 2 - soluzione



ESERCIZIO

Esercizio 2 - soluzione

Possiamo calcolare quindi in χ^2 :

$$\chi^2 = \frac{(8 - 5.26)^2}{5.26} + \frac{(10 - 13.33)^2}{13.33} + \frac{(23 - 24.78)^2}{24.78} + \frac{(30 - 27.82)^2}{27.82} + \frac{(18 - 18.87)^2}{18.87} + \frac{(11 - 9.94)^2}{9.94} = 2.71$$

I gradi di libertà sono 3 poiché ci sono $k=6$ osservazioni ma sono stati usati $m=2$ parametri derivati dai dati campionari: media e deviazione standard. Quindi: $v = k - 1 - m = 6 - 1 - 2 = 3$.

Dalle tavole del chi-quadrato con $\alpha = 0.05$ per $v = 3$ si ha che il valore limite è $\chi^2 = 7.81$, poiché $2.71 < 7.81$ allora l'ipotesi nulla non è rifiutata.

Si può dire che la distribuzione del campione approssima la normale in modo accettabile.

TEST DI CONTINGENZA

Si usa per verificare se le osservazioni sono contingenti, ossia dipendenti, dalle condizioni in cui si sono verificate.

Si usa quando si vuole vedere se esiste una relazione tra due variabili categoriche: si incrociano queste due variabili in una **tabella di contingenza**

In ogni casella della tabella troviamo il numero di osservazioni che presenta una particolare combinazione delle categorie delle due variabili.

Si usano le **tabelle di contingenza** (2×2 , 2×3 , 3×3 ecc.)

In questo specifico test, l'ipotesi H_0 solitamente si imposta come:

H_0 : non esiste dipendenza tra le variabili categoriche

TEST DI CONTINGENZA

Frequenze Osservate

Studio sull'efficacia dei caschi protettivi per ciclisti nella prevenzione dei traumi cranici. Su un totale di 793 ciclisti che hanno subito incidenti, 235 hanno riportato un trauma e, fra questi, 17 portavano il casco. Fra i restanti ciclisti (558) che non hanno riportato un trauma, 130 portavano il casco.

Si riportano i risultati dell'indagine (**FREQUENZE OSSERVATE**):

	Con casco	Senza casco	Totale	
Trauma	17	218	235	29.6%
No trauma	130	428	558	70.4%
Totale	147	646	793	
	18.5%	81.5%		

P di riportare traumi:

$$235/793 = 29.6\%$$

P di non riportare traumi:

$$558/793 = 70.4\%$$

P di portare il casco:

$$147/793 = 18.5\%$$

P di non portare il casco:

$$646/793 = 81.5\%$$

Esiste una relazione tra l'uso del casco nei ciclisti e la presenza di trauma in caso di incidente?

TEST DI CONTINGENZA

Frequenze Attese (modo 1)

Se non ci fosse nessuna relazione fra la presenza di un trauma e il fatto di portare il casco, le percentuali totali di riga dovrebbero essere uguali in tutte le colonne

	Con casco	Senza casco	Totale
Trauma	29.6%	29.6%	235 (29,6%)
No trauma	70.4%	70.4%	558 (70.4%)
Totale	147	646	793

CALCOLO FREQUENZE ATTESE

1) Con casco

$$147 * 0.296 = 43.6 \text{ soggetti con traumi}$$

$$147 * 0.704 = 103.4 \text{ soggetti senza traumi}$$

2) Senza casco

$$646 * 0.296 = 191.4 \text{ soggetti con traumi}$$

$$646 * 0.704 = 454.6 \text{ soggetti senza traumi}$$

	Con casco	Senza casco	Totale
Trauma	43.6	191.4	235
No trauma	103.4	454.6	558
Totale	147	646	793

TEST DI CONTINGENZA

Frequenze Attese (modo 2)

Se non ci fosse nessuna relazione fra la presenza di un trauma e il fatto di portare il casco, le percentuali totali di colonna dovrebbero essere uguali in tutte le righe

	Con casco	Senza casco	Totale
Trauma	18.5%	81.5%	235
No trauma	18.5%	81.5%	558
Totale	147 (18.5%)	646 (81.5%)	793

CALCOLO FREQUENZE ATTESE

1) Trauma

$$235 * 0.185 = 43.6 \text{ soggetti con casco}$$

$$235 * 0.825 = 191.4 \text{ soggetti senza casco}$$

2) No trauma

$$558 * 0.185 = 103.4 \text{ soggetti con casco}$$

$$558 * 0.825 = 454.6 \text{ soggetti senza casco}$$

	Con casco	Senza casco	Totale
Trauma	43.6	191.4	235
No trauma	103.4	454.6	558
Totale	147	646	793

TEST DI CONTINGENZA

Frequenze attese (modo 3)

La frequenza attesa di ciascuna cella si può calcolare con la seguente formula


$$freq.attesa = \frac{\text{totale riga} * \text{totale colonna}}{\text{totale generale}}$$

	Con casco	Senza casco	Totale
Trauma	17 $(235*147)/793 = 43.6$	218 $(235*646)/793 = 191.4$	235
No trauma	130 $(558*147)/793 = 103.4$	428 $(558*646)/793 = 454.6$	558
Totale	147	646	793

Le frequenze attese si confrontano con le frequenze osservate mediante il test del chi-quadrato


TEST DI CONTINGENZA

	Con casco	Senza casco	Totale
Trauma	17	218	235
No trauma	130	428	558
Totale	147	646	793



Frequenze
osservate

	Con casco	Senza casco	Totale
Trauma	43.6	191.4	235
No trauma	103.4	454.6	558
Totale	147	646	793



Frequenze
attese

$$\chi^2 = \frac{(17 - 43.6)^2}{43.6} + \frac{(130 - 103.4)^2}{103.4} + \frac{(218 - 191.4)^2}{191.4} + \frac{(428 - 454.6)^2}{454.6}$$

$$\chi^2 = 28.26$$

TEST DI CONTINGENZA

Gradi di libertà

Per la costruzione della tabella di contingenza delle frequenze attese abbiamo stimato le probabilità sia per ogni riga, sia per ogni colonna, quindi:

La distribuzione campionaria di questa sommatoria è approssimata da una distribuzione χ^2 con

$$(r - 1) * (c - 1) \text{ gl}$$

$r = \text{numero righe}$

$c = \text{numero colonne}$

Per una tabella 2x2

$$\text{gl} = (2 - 1) * (2 - 1) = 1$$

Se il valore di χ^2 trovato è maggiore del valore tabulato per α pari a 0.05, si deve concludere che le frequenze osservate differiscono significativamente da quelle attese.

TEST DI CONTINGENZA

$$\chi^2 = 28.26$$

$$gl = (2-1)*(2-1)=1$$

χ^2 tabulato per $\alpha=0.05$ e 1 gl = 3.84

Il numero di soggetti che hanno riportato traumi non sono uguali nelle due popolazioni (con casco/senza casco), rifiuto l'indipendenza dell'ipotesi H_0

L'uso del casco riduce la frequenza dei traumi cranici

TEST DI CONTINGENZA

- Il test di contingenza verifica se esiste o meno un'associazione (a livello di significatività α) tra variabili categoriche
- Può essere applicato su un numero arbitrario di categorie
- Il suo esito porta alla conclusione di indipendenza o meno tra le variabili in esame (non quanto forte la dipendenza)

FORMULARIO

Risulta possibile calcolare direttamente χ^2 senza calcolare le frequenze attese in una tabella 2x2

a	b	a+b
c	d	c+d
a+c	b+d	a+b+c+d = N

a, b, c, d le frequenze osservate

$$\chi^2 = \frac{(ad - bc)^2 N}{(a + b)(c + d)(a + c)(b + d)}$$

Nell'esempio precedente

$$\chi^2 = \frac{(17 * 428 - 218 * 120)^2 * 793}{235 * 558 * 147 * 646} = 28.26$$

	Con casco	Senza casco	Totale
Trauma	17	218	235
No trauma	130	428	558
Totale	147	646	793

ESERCIZIO

Esercizio 1

Si dispone delle seguenti informazioni campionarie sulla soddisfazione per un servizio di vendita online secondo il titolo di studio della clientela:

	Licenza elementare o media	Diploma	Laurea e post laurea
Molto soddisfatto	7	10	9
Abbastanza soddisfatto	12	28	18
Abbastanza insoddisfatto	14	12	9
Del tutto insoddisfatto	4	14	5

Valutare la dipendenza/indipendenza dei giudizi dal titolo di studio.

ESERCIZIO

Esercizio 1 - soluzione

Siccome vogliamo valutare la discrepanza esistente tra le frequenze osservate e quelle attese su una serie di dati usiamo il test del chi-quadrato con ipotesi nulla:

H_0 : le variabili sono indipendenti.

Calcoliamo quindi il totale delle frequenze osservate e le percentuali per riga e per colonna.

	Licenza elementare o media	Diploma	Laurea o post laurea	Totale	%
Molto soddisfatto	7	10	9	26	0.18
Abbastanza soddisfatto	12	28	18	58	0.41
Abbastanza insoddisfatto	14	12	9	35	0.25
Del tutto insoddisfatto	4	14	5	23	0.16
Totale	37	64	41	142	1.00
%	0.26	0.45	0.29	1.00	

ESERCIZIO

Esercizio 1 - soluzione

Calcoliamo le frequenze attese seguendo le percentuali per riga o quelle per colonna, il risultato deve essere lo stesso. **(Totale Riga * Totale Colonna)/Totale Generale**

	Licenza element are o media	Diploma	Laurea o post laurea	Totale
Molto soddisfatto	6.77	11.72	7.51	26
Abbastanza soddisfatto	15.11	26.14	16.75	58
Abbastanza insoddisfatto	9.12	15.77	10.11	35
Del tutto insoddisfatto	5.99	10.37	6.64	23
Totale	37	64	41	142

ESERCIZIO

Esercizio 1 - soluzione

Calcoliamo il chi-quadro

$$\begin{aligned}\chi^2 &= \frac{(7 - 6.77)^2}{6.77} + \frac{(10 - 11.72)^2}{11.72} + \frac{(9 - 7.51)^2}{7.51} + \frac{(12 - 15.11)^2}{15.11} \\ &+ \frac{(28 - 26.14)^2}{26.14} + \frac{(18 - 16.75)^2}{16.75} + \frac{(14 - 9.12)^2}{9.12} + \frac{(12 - 15.77)^2}{15.77} \\ &+ \frac{(9 - 10.11)^2}{10.11} + \frac{(4 - 5.99)^2}{5.99} + \frac{(14 - 10.37)^2}{10.37} + \frac{(5 - 6.64)^2}{6.64} = \\ &= 7.401\end{aligned}$$

Gradi di libertà: $(4-1)*(3-1) = 6$

$\chi^2(\text{g.l.}=6, \alpha=0.05) = 12.59$.

Siccome $7.401 < 12.59$ non rifiuto l'ipotesi nulla

MISURA DI ASSOCAZIONE – ODDS RATIO

La misura per valutare l'associazione tra esposizione ad un fattore di rischio ed una malattia è l'Odds Ratio (OR), cioè il rapporto tra **odds**

ODDS

Per una variabile in una singola prova sono possibili 2 risultati :
successo/insuccesso

p = probabilità di successo **$1 - p$ = probabilità di insuccesso**

L'odds di un successo è:

$$O = \frac{p}{1 - p}$$

ODDS RATIO

È il rapporto tra l'odds del successo di un gruppo e l'odds di successo di un altro gruppo:

$$OR = \frac{O_1}{O_2}$$

MISURA DI ASSOCAZIONE – ODDS RATIO

1) Calcolo dell'odds nei **CASI**

	Casi (M⁺)	Controlli (M⁻)	Totale
Esposti (Exp)	a	b	a + b
Non esposti (Exp⁻)	c	d	c + d
Totale	a + c	b + d	

La probabilità che i malati siano stati esposti in passato al fattore di rischio è:

$$a/a+c$$

La probabilità che i malati non siano stati esposti in passato al fattore di rischio è:

$$c/a+c$$

$$\text{Odds esposizione nei malati} = \frac{\frac{a}{a+c}}{\frac{c}{a+c}} = \frac{a}{a+c} \times \frac{a+c}{c} = \frac{a}{c}$$

MISURA DI ASSOCAZIONE – ODDS RATIO

2) Calcolo dell'odds nei **CONTROLLI**

	Casi (M⁺)	Controlli (M⁻)	Totale
Esposti (Exp)	a	b	a + b
Non esposti (Exp⁻)	c	d	c + d
Totale	a + c	b + d	

La probabilità che i non malati (o controlli) siano stati esposti in passato al fattore di rischio è:

$$b/b+d$$

La probabilità che i non malati (o controlli) non siano stati esposti in passato al fattore di rischio è:

$$d/b+d$$

$$\text{Odds esposizione nei non malati} = \frac{\frac{b}{b+d}}{\frac{d}{b+d}} = \frac{b}{b+d} \times \frac{b+d}{d} = \frac{b}{d}$$

MISURA DI ASSOCAZIONE – ODDS RATIO

LIMITI DI CONFIDENZA DELL'OR

Per misurare la rilevanza statistica di un OR si usa l'**IC** (Intervallo di Confidenza) è un range di valori che con una P del 95% contiene l'OR reale

La distribuzione campionaria dell'OR è asimmetrica a destra. E' necessario convertire l'OR nel suo logaritmo naturale. I limiti al 95% sono:

$$\ln(OR) \pm 1.96 * ES[\ln(OR)]$$

$$ES[\ln(OR)] = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$$

MISURA DI ASSOCAZIONE – ODDS RATIO

Risulta necessario riconvertire due valori logaritmici $\ln_1$ ed $\ln_2$ dell'intervallo di confidenza in OR, mediante elevamento a potenza di $e = 2.71828$

$$OR_1 = e^{\ln_1} = 2.71828^{\ln_1}$$

$$OR_2 = e^{\ln_2} = 2.71828^{\ln_2}$$

L' IC dell'OR consente di verificare la significatività

- Se contiene 1, H_0 è accettata: mancanza di associazione
- Se non contiene 1, H_0 rifiutata: associazione significativa

Deve contenere 1 (nessuna dipendenza) per soddisfare l'ipotesi H_0

MISURA DI ASSOCIAZIONE – ODDS RATIO

		urolitiasi	
		SI	NO
obesità	SI	383	322
	NO	631	1165

Studio di associazione tra l'obesità nel cane (fattore di esposizione) e la presenza di calcolosi urinaria (malattia)

Da:
https://www.quadernodiepidemiologia.it/epi/cause/ris_rel.htm

Risultati dello studio retrospettivo



		calcolosi urinaria		
		+	-	
obesità	+	383 ^a	322 ^b	705 → totale esposti
	-	631 ^c	1165 ^d	1796 → totale non esposti
		1014 → totale casi	1487 → totale controlli	2501

variabile indipendente (esposizione) ←

→ variabile dipendente (malattia)

ODDS di esposizione nei casi:
 $383 / 631 = 0.607$

ODDS di esposizione nei controlli:
 $322 / 1165 = 0.277$

ODDS RATIO = $0.607 / 0.277 = 2.19$

Calcolo alternativo:
 $(383 \cdot 1165) / (322 \cdot 631) = 2.19$

MISURA DI ASSOCAZIONE – ODDS RATIO

Calcolo dell'intervallo di confidenza

1) Convertire Or nel suo logaritmo naturale

2) $OR = 2.19$ $\ln(2.19) = 0.784$

3) Calcolo ES($\ln OR$)

$$ES[\ln(OR)] = \sqrt{\frac{1}{383} + \frac{1}{322} + \frac{1}{631} + \frac{1}{1165}} = 0.09$$

3) Calcolo limiti

LI $0.784 - 1.96 * 0.09 = 0.607$

LS $0.784 + 1.96 * 0.09 = 0.96$

$$0.607 < \ln(OR) < 0.96$$

4) Riconvertire i valori logartimici

LI $e^{0.607} = 1.83$

LS $e^{0.967} = 2.61$

$$1.83 < OR < 2.61$$

L'intervallo non contiene 1, quindi l'associazione tra obesità e calcolosi urinaria è significativa

MISURA DI ASSOCAZIONE – ODDS RATIO

Intervallo di confidenza dell'OR

- Gli intervalli di confidenza di Odds Ratio esprimono il grado di precisione con cui il valore trovato su un campione rappresenta la stima del valore 'reale' di tutta la popolazione
- Gli intervalli di confidenza al 95% identificano un range di valori che con una attendibilità pari al 95% contiene anche il valore 'reale'

L'intervallo di confidenza di Odds ratio consente di verificare la 'significatività statistica' dei risultati in quanto

- se contiene il valore 1 l'ipotesi nulla viene soddisfatta
- se non contiene il valore di uno l'ipotesi nulla viene riusata e il risultato viene definito significativo



MISURA DI ASSOCAZIONE – ODDS RATIO

Esempio: in uno studio caso-controllo sono confrontati 379 individui affetti da cancro al pancreas e 644 controlli.

La valutazione retrospettiva dell'esposizione al fumo di sigarette dà origine alla seguente tabella:

	<i>Cancro al pancreas</i>		<i>Totale</i>
	<i>Sì</i>	<i>No</i>	
<i>Fumatori</i>	310	275	585
<i>Non fumatori</i>	69	369	438
<i>Totale</i>	379	644	1023

$$OR = (310 \times 369) : (275 \times 69) = 6 \rightarrow \ln(6) = 1.79$$

$$\text{Intervallo di confidenza} = 1.79 \pm 1.96 * 0.155$$

Riconversione tramite la potenza e^{LI} e^{LS}

$$4.45 < OR < 8.17$$

Tra cancro al pancreas e fumo c'è una forte e significativa associazione

ODDS RATIO

L'analisi dell'intervallo di confidenza dell'odds ratio:

- Si concentra su due **categorie binarie**
- Fornisce una misura della forza dell'associazione (se esiste)
- Calcola un intervallo che con una certa probabilità ($1-\alpha\%$) conterrà il vero valore di odds per la popolazione
- La verifica non è fatta direttamente per capire se c'è o meno dipendenza, ma permette di capirlo (se l'1 è all'interno dell'IC, allora odds non è significativo)

ESERCIZIO

Esercizio 1

Uno degli argomenti più dibattuti nella letteratura scientifica è quello dell'eventuale ruolo degli ormoni estro-progestinici (pillola) nello sviluppo del tumore della mammella.

In tal senso, uno dei più autorevoli contributi è costituito da uno studio caso-controllo multicentrico effettuato in Scandinavia che ha preso in considerazione:

- Casi: donne con carcinoma mammario;
- Controlli: donne sane.

In entrambi i gruppi si è studiato l'eventuale uso della pillola (esposte e non esposte).

Lo studio ha riportato i seguenti risultati:

422 donne con carcinoma mammario (Casi): 326 Esposte e 96 Non esposte

527 donne sane (Controlli): 371 Esposte e 156 Non esposte

Con questi dati: è possibile valutare il ruolo del fattore di rischio considerato (uso della pillola) nell'eziopatogenesi del carcinoma mammario?

ESERCIZIO

Esercizio 1 - soluzione

	Casi (Malati)	Controlli (Non malati)
Esposti (uso della pillola)	326	371
Non esposti	96	156
Totale	422	527

$$OR = \frac{326 * 156}{371 * 96} = 1.428$$

Formula semplificata per tabella 2x2

ESERCIZIO

Esercizio 1 - soluzione

1) Calcolo $\ln(OR) = \ln(1.428) = 0.356$

2) Calcolo $ES[\ln(OR)]$:

$$ES[\ln(OR)] = \sqrt{\frac{1}{326} + \frac{1}{371} + \frac{1}{96} + \frac{1}{156}} = 0.15$$

3) Calcolo i limiti

4) LI $0.356 - 1.96 * 0.15 = 0.062$

5) LS $0.356 + 1.96 * 0.15 = 0.65$

6) Riconvertire i valori logaritmici

7) LI $e^{0.062} = 1.064$

8) LS $e^{0.65} = 1.95$

9) $1.064 < OR < 1.95$

L'intervallo non contiene 1, quindi secondo questo studio c'è una associazione statisticamente rilevante (di poco) tra assunzione di ormoni estro-progestinici (pillola) e sviluppo del tumore della mammella.