



UNIVERSITÀ DEGLI STUDI
DI MILANO

INFORMATICA E BIOSTATISTICA

Anno Accademico 2024-2025




ANOVA – Analysis Of VAriance

- L'ANOVA è l'analisi della varianza (**Analysis of variance**) è un test statistico utilizzato per confrontare le medie di **due o più gruppi** e verificarne le differenze statistiche
- L'ANOVA può essere considerata una generalizzazione del test **t di Student**
- Il concetto chiave è l'idea di confrontare la variabilità intra-gruppo e quella inter-gruppo
- Questa analisi ha principalmente due obiettivi:
 - 1) **Capire se le medie di gruppi distinti** possono essere considerate **uguali** (o diverse)
 - 2) Individuare quanta **parte della variabilità di una certa caratteristica** possa essere **spiegata attraverso la suddivisione** delle unità statistiche **in gruppi**

ANOVA

In che modi si può scomporre la varianza?



ANOVA

Per descrivere la variabilità delle osservazioni è possibile sfruttare un modello del tipo:

$$y_{mn} = \mu + \alpha_m + e_{mn}$$

L' n^{esima} osservazione dell' m^{esimo} fattore (y_{mn}) è il risultato di:

- 1) Una media comune a tutte le osservazioni (μ)
- 2) L'effetto dell' m^{esimo} livello del **fattore** α (il gruppo di appartenenza)
- 3) L'effetto casuale, detto errore (e_{mn} dato dalla singola osservazione e dal fattore di appartenenza)

ANOVA – Esempio

Intervistiamo 12 soggetti chiedendogli quante ore passano ogni settimana davanti ai social.

Suddividiamo in tre gruppi sulla base dell'età.

Ci sono 4 giovani, 5 adulti e 3 anziani.

Riportiamo le risposte fornite nella seguente tabella.

Giovani [15-30]	adulti [31-50]	anziani [51-65]
20	18	5
25	16	9
17	11	3
32	5	
	12	

- 1) Le medie dei tre gruppi possono essere considerate uguali?
- 2) Quanta parte della variabilità del numero di ore può essere spiegata con la suddivisione in questi tre gruppi?

ANOVA

L'analisi della varianza (ANOVA) si basa su un rapporto di varianze (distribuzione F) e ha lo scopo

1. Di confrontare le medie di due o più gruppi

FATTORE è la variabile che ha un effetto sulla variabile dipendente e può avere diversi LIVELLI (gruppi)

Analisi fattoriale

$$y_{mn} = \mu + \alpha_m + e_{mn}$$

Es: Si analizza il peso degli animali sottoposti a 3 diete

Peso è la variabile dipendente (y), dipendente dall'elemento selezionato (n) e dal livello a cui appartiene (m)

Dieta è il fattore (α) che può influire sul peso e ha 3 livelli(m)

2. Di verificare se il coefficiente di regressione (b) è significativamente diverso da zero

Analisi della varianza applicata alla regressione

$$y_i = a + bx_i + e$$

oppure

$$y_i = \mu + bx_i + e$$

MODELLO FATTORIALE AD UN CRITERIO DI CLASSIFICAZIONE

- L'ANALISI DELLA VARIANZA permette di confrontare simultaneamente le medie di più gruppi (a differenza del test t di Student)
- L'ANOVA '*ad un criterio di classificazione*' o '*a una via*' indica che esiste una sola caratteristica (o FATTORE) che distingue le popolazioni.
- L'ANOVA a 2 vie include 2 criteri di classificazione quindi due fattori che distinguono la popolazione.
- I MODELLI FATTORIALI INCLUDONO 1 o PIU' CRITERI DI CLASSIFICAZIONI (FATTORI)

ANOVA – UNA VIA

- La **variabilità** è associata alla devianza presente nella formula della varianza: Somma di Scarti quadrati (Sum of Squares) → **SS**
- Alle SS sono associati i relativi gradi di libertà (**gl** o df, degrees of freedom)
- Le SS divise i gl determinano le varianze **MS** (Mean Squares)
- Il rapporto **F**, applicando la distribuzione, si utilizza per testare H_0
- SS e gl godono di proprietà additiva
- L'ipotesi nulla si imposta come **H_0 : le medie dei gruppi sono UGUALI** (a seconda di quanti gruppi)

FV	SS	gl	MS	F
Tra gruppi (Between) Modello	SSB/SS_m	N_m-1	$MS_m : SSB/(N_m-1)$	MS_m/MS_e
Entro gruppi (Within) Errore	SSW/SS_e	$N-M$	$MS_e : SSW/(N-M)$	
Totale corretto	SST	$N-1$		

N = totale osservazioni

M = totale gruppi

ANOVA – UNA VIA

$$\bar{x} = \frac{1}{N} \sum_{i=1}^M \sum_{j=1}^{N_i} x_{ij} \quad \bar{x}_i = \frac{1}{N_i} \sum_{j=1}^{N_i} x_{ij}$$

$$SSB = \sum_{i=1}^M N_i (\bar{x}_i - \bar{x})^2 \quad SSW = \sum_{i=1}^M \sum_{j=1}^{N_i} (x_{ij} - \bar{x}_i)^2$$

$$SST = \sum_{i=1}^M \sum_{j=1}^{N_i} (x_{ij} - \bar{x})^2 = SSB + SSW$$

M = il totale dei gruppi/fattori



N_i = numerosità del gruppo/fattore

ANOVA – STATISTICA F

Dalla scomposizione della varianza si ottiene:

$$F = \frac{\text{Varianza del modello}}{\text{Varianze dell'errore}} = \frac{MSB}{MSW}$$

- Statistica test dell'ANOVA
- Parametro associato ad una distribuzione di probabilità: F
- Limiti: da 0 a $+\infty$
- All'aumentare di F, il modello è sempre più importante (SIGNIFICATIVO) nello spiegare la variabilità del carattere.
- È in funzione dei gradi di libertà del numeratore e del denominatore



ANOVA – STATISTICA F

Il valore soglia $F_{gl1, gl2}$ definisce l'area α al di sotto della coda destra della distribuzione F con $gl1$ e $gl2$.

Per trovare un valore critico nella tavola i gradi di libertà del numeratore ($gl1$) e i gradi di libertà del denominatore ($gl2$)

$$\alpha = 0.05$$

G.L.		NUMERATORE							
		1	2	3	4	5	6	7	8
D E N O M I N A T O R E	1	161.4	199.5	215.7	224.6	230.2	234	236.8	238.9
	2	18.51	19	19.16	19.25	19.3	19.33	19.35	19.37
	3	10.13	9.552	9.277	9.117	9.013	8.941	8.887	8.845
	4	7.709	6.944	6.591	6.388	6.256	6.163	6.094	6.041
	5	6.608	5.786	5.409	5.192	5.05	4.95	4.876	4.818
	6	5.987	5.143	4.757	4.534	4.387	4.284	4.207	4.147
	7	5.591	4.737	4.347	4.12	3.972	3.866	3.787	3.726
	8	5.318	4.459	4.066	3.838	3.688	3.581	3.5	3.438
	9	5.117	4.256	3.863	3.633	3.482	3.374	3.293	3.23
	10	4.965	4.103	3.708	3.478	3.326	3.217	3.135	3.072
	11	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948
	12	4.747	3.885	3.49	3.259	3.106	2.996	2.913	2.849
	13	4.667	3.806	3.411	3.179	3.025	2.915	2.832	2.767
	14	4.6	3.739	3.344	3.112	2.958	2.848	2.764	2.699
	15	4.543	3.682	3.287	3.056	2.901	2.79	2.707	2.641
	16	4.494	3.634	3.239	3.007	2.852	2.741	2.657	2.591
	17	4.451	3.592	3.197	2.965	2.81	2.699	2.614	2.548
	18	4.414	3.555	3.16	2.928	2.773	2.661	2.577	2.51
	19	4.381	3.522	3.127	2.895	2.74	2.628	2.544	2.477
	20	4.351	3.493	3.098	2.866	2.711	2.599	2.514	2.447
	21	4.325	3.467	3.072	2.84	2.685	2.573	2.488	2.42
	22	4.301	3.443	3.049	2.817	2.661	2.549	2.464	2.397
	23	4.279	3.422	3.028	2.796	2.64	2.528	2.442	2.375
	24	4.26	3.403	3.009	2.776	2.621	2.508	2.423	2.355
	25	4.242	3.385	2.991	2.759	2.603	2.49	2.405	2.337

ANOVA – ESEMPIO

Esempio: peso(kg) di 20 bovine distribuite in 3 allevamenti:

Animale	Peso (Y)	Torace (X)	Razza	Allevamento	Animale	Peso (Y)	Torace (X)	Razza	Allevamento
a	85.0	101	1	A	m	202.0	134	2	C
b	154.5	119	1	A	n	85.5	103	1	C
c	180.0	134	1	C	o	73.5	96	2	B
d	71.5	92	2	A	p	219.0	148	1	A
e	93.0	110	2	B	q	113.0	108	2	C
f	156.5	135	1	A	r	149.5	120	2	C
g	133.5	119	1	B	s	106.5	107	2	B
h	112.5	114	2	B	t	166.0	134	1	C
i	114.5	115	2	A	u	118.0	116	1	B
l	96.5	105	2	A	v	149.0	126	1	B

FV	SS	gl	MS	F
Tra Allevamenti	4441	2	2220.5	1.3
Errore	29138	17	1714	
Totale corretto	33579	19		

ANOVA – ESEMPIO

G.L.		N	
		1	2
D E N O M I N A T O R E	1	161.4	199.5
	2	18.51	19
	3	10.13	9.552
	4	7.709	6.944
	5	6.608	5.786
	6	5.987	5.143
	7	5.591	4.737
	8	5.318	4.459
	9	5.117	4.256
	10	4.965	4.103
	11	4.844	3.982
	12	4.747	3.885
	13	4.667	3.806
	14	4.6	3.739
	15	4.543	3.682
	16	4.494	3.634
	17	4.451	3.592
	18	4.414	3.555

Ipotesi nulla dell'ANOVA a una via

H_0 : le medie dei gruppi sono uguali

Il valore trovato $F = 1.3$ è inferiore a quello tabulato per 2 e 17 GL ($= 3.592$) per $\alpha = 0.05$ (infatti $P = 0.2995$)

Accetto l'ipotesi nulla

Le medie dei 3 allevamenti sono uguali

Il fattore 'allevamento' non ha un effetto significativo sul peso

FV	SS	gl	MS	F	P
Tra Allevamenti	4441	2	2220.5	1.3	>0.05 (=0.2995)
Errore	29138	17	1714		
Totale corretto	33579	19			

COEFFICIENTE DI DETERMINAZIONE

Dalla scomposizione della varianza si ricava anche :

R^2 o coefficiente di determinazione

$$R^2 = \frac{\text{SS Modello}}{\text{SS Totale Corretto}} = \frac{SSB}{SST}$$

R^2 = devianza del modello/devianza totale

Limiti: da 0 a 1

0 = il modello non spiega la variabilità del carattere

1 = il modello spiega tutta la variabilità del carattere

Nell esempio:

$$R^2 = 4441/33579 = 0.1322$$

Il 13.2% della variabilità del carattere y è spiegata dal modello utilizzato (l'allevamento spiega il 13.2% della variabilità del peso)

ANOVA – DUE VIE (2 Fattori)

Animale	Peso (Y)	Torace (X)	Razza	Allevamento	Animale	Peso (Y)	Torace (X)	Razza	Allevamento
a	85.0	101	1	A	m	202.0	134	2	C
b	154.5	119	1	A	n	85.5	103	1	C
c	180.0	134	1	C	o	73.5	96	2	B
d	71.5	92	2	A	p	219.0	148	1	A
e	93.0	110	2	B	q	113.0	108	2	C
f	156.5	135	1	A	r	149.5	120	2	C
g	133.5	119	1	B	s	106.5	107	2	B
h	112.5	114	2	B	t	166.0	134	1	C
i	114.5	115	2	A	u	118.0	116	1	B
l	96.5	105	2	A	v	149.0	126	1	B

Esempio: peso(kg) di 20 bovine dipende dal fattore allevamento che ha 3 livelli e dal fattore razza che ha 2 livelli ?

$$y_{lmn} = \mu + \alpha_m + \beta_l + e_{lmn}$$

ANOVA – DUE VIE (2 Fattori)

FV	SS	GL	MS	F
Tra allevamenti	4440	2 (3-1)	2220	1.52
Tra razze	4945	1 (2-1)	4945	3.37
Tra allevamenti e razze	13071	2 (3-1)*(2-1)	6535	4.46
Errore	20508	14	1465	
Totale corretto	42964	19		

- **H_0 : le medie dei 3 allevamenti sono uguali**
- Allevamento: $F = 2220/1465 = 1.52$; tavole $F(2, 14 \text{ GL}; \alpha=0.05) = 3.74 \blacktriangleright 1.52 < 3.74$
- **H_0 : le medie delle 2 razze sono uguali**
- Razza: $F = 4945/1465 = 3.37$; tavole $F(1, 14 \text{ GL}; \alpha=0.05) = 4.60 \blacktriangleright 3.37 < 4.60$
- **H_0 : le medie nei gruppi combinazione delle 2 razze e dei 3 allevamenti sono uguali**
- Razza: $F = 6535/1465 = 4.46$; tavole $F(2, 14 \text{ GL}; \alpha=0.05) = 3.74 \blacktriangleright 4.46 > 3.74$

Per modelli con più di un fattore, SS del numeratore di R^2 è dato dalla somma di tutti gli SS per ogni fattore e per ogni combinazione di fattori. $SS_m = 22456$

$$R^2 = 22456/42964 = 0.522$$

Il 52.2%% della variabilità del peso è spiegata dal modello (razza + allevamento).

ANOVA – COEFFICIENTE DI REGRESSIONE

L'analisi della varianza (ANOVA) si basa su un rapporto di varianze (F) e ha lo scopo:

2. Di verificare se il coefficiente di regressione (b) è significativamente diverso da zero

Analisi della varianza applicata alla regressione

$$y_i = a + bx_i + e$$

oppure

$$y_i = \mu + bx_i + e$$


FV	SS	GL	MS	F
Modello	$SS_m = (bx - \bar{y})^2$	$r - 1$	$SS_m / r - 1 = MS_m$	MS_m / MS_e
Errore	$SS_e = (y - bx)^2$	$n - r$	$SS_e / n - r = MS_e$	
Totale corretto	$SS_T = SS_m + SS_e$	$n - 1$	$SS_T / n - 1 = MS_T$	

ANOVA – COEFFICIENTE DI REGRESSIONE

Un qualsiasi modello (regressione o fattoriale) può essere definito:

$$\mathbf{Y} = \mathbf{Xb} + \mathbf{e}$$

$\mathbf{Xb}$ può essere $(\mu + bx_i)$ oppure $(\mu + \alpha_m)$



$$SSB = SS_m = \sum (bx_i - \bar{y})^2 \quad \text{Somma dei quadrati associati al modello}$$

$$SSW = SS_e = \sum (y_i - bx_i)^2 \quad \text{Somma dei quadrati associati all'errore}$$

ANOVA – COEFFICIENTE DI REGRESSIONE

FV	SS	GL	MS	F
Modello	$SS_m = (bx - \bar{y})^2$	$r - 1$	$SS_m / r - 1 = MS_m$	MS_m / MS_e
Errore	$SS_e = (y - bx)^2$	$n - r$	$SS_e / n - r = MS_e$	
Totale corretto	$SS_T = SS_m + SS_e$	$n - 1$	$SS_T / n - 1 = MS_T$	

- Se il rapporto $F = 1$ significa che MS_m e MS_e sono uguali e pertanto **la variabilità spiegata dal modello (MS_m) è uguale a quella “naturale” o casuale (MS_e)**: il modello non spiega nulla, i fattori che include non spiegano variabilità diversa da quella naturale.
- Se $F > 1$ **il modello spiega più variabilità di quella casuale** e per saperne di più dobbiamo confrontare F con una apposita tabella.
- Il valore di F trovato con l'analisi deve essere confrontato con un valore tabulare da ricercare con 2 parametri: i **gl.** del numeratore e quelli del denominatore che lo hanno prodotto.


ANOVA – REGRESSIONE

Animale	Peso (Y)	Torace (X)	Razza	Allevamento	Animale	Peso (Y)	Torace (X)	Razza	Allevamento
a	85.0	101	1	A	m	202.0	134	2	C
b	154.5	119	1	A	n	85.5	103	1	C
c	180.0	134	1	C	o	73.5	96	2	B
d	71.5	92	2	A	p	219.0	148	1	A
e	93.0	110	2	B	q	113.0	108	2	C
f	156.5	135	1	A	r	149.5	120	2	C
g	133.5	119	1	B	s	106.5	107	2	B
h	112.5	114	2	B	t	166.0	134	1	C
i	114.5	115	2	A	u	118.0	116	1	B
l	96.5	105	2	A	v	149.0	126	1	B

La tabella riporta il peso (in Kg) e la circonferenza toracica (in cm) di 20 bovini appartenenti a 2 razze (1 e 2) e distribuiti in 3 allevamenti (A, B e C)

Se ci fosse una perfetta relazione tra x e y, i punti si troverebbero sulla retta: tutta la variabilità sarebbe spiegata dal b di regressione.

Al contrario, solo una parte è spiegata dal b di regressione; la parte restante non è spiegata (errore)



ANOVA – REGRESSIONE

L'ipotesi nulla $H_0: b=0$, ossia y non cambia al variare di x, la pendenza è 0

FV	SS	GL	MS	F
Modello	$SS_m = (bx - \bar{y})^2$	$r - 1$	$SS_m / r - 1 = MS_m$	MS_m / MS_e
Errore	$SS_e = (y - bx)^2$	$n - r$	$SS_e / n - r = MS_e$	
Totale corretto	$SS_T = SS_m + SS_e$	$n - 1$	$SS_T / n - 1 = MS_T$	

FV	SS	GL	MS	F
Regressione	30948	1	30948	$30948 / 146.2 = 211.7$
Errore	2631	18	146.2	
Totale corretto	33579	19		

Si cerca sulle tavole il valore soglia di F per

- 1 gl al numeratore
- 18 gl al denominatore : $N - 1 - GL$ di ogni modello

ANOVA – REGRESSIONE

	1
1	161.4
2	18.51
3	10.13
4	7.709
5	6.608
6	5.987
7	5.591
8	5.318
9	5.117
10	4.965
11	4.844
12	4.747
13	4.667
14	4.6
15	4.543
16	4.494
17	4.451
18	4.414

Il valore trovato di F (211.7) è maggiore del valore tabulato di 4.414 e si trova nella coda della distribuzione F.

La probabilità di trovare $F = 19.18$ è minore del 5% ($P < 0.05$)

Rifiutiamo l'ipotesi nulla che $b = 0$ e che non ci sia correlazione tra x e y

La probabilità di sbagliare nel caso H_0 sia giusta (Errore di Tipo 1) è minore del 5%

FV	SS	GL	MS	F	P
Regressione	30948	1	30948	211.7	<0.0001
Errore	2631	18	146.2		
Totale corretto	33579	19			

ANOVA – REGRESSIONE

Dalla scomposizione della varianza si ricava anche :

R^2 o coefficiente di determinazione

$$R^2 = \frac{\text{SS del modello}}{\text{SS totale corretto}}$$

$R^2 = \text{devianza del modello} / \text{devianza totale}$

Limiti: da 0 a 1

0 = il modello non spiega la variabilità del carattere

1 = il modello spiega tutta la variabilità del carattere

Nell esempio:

$$R^2 = 30948 / 33579 = 0.92$$

Il 92% della variabilità del carattere y (peso) è spiegata dal modello di regressione adattato

ANOVA MISTA

FATTORIALE + REGRESSIONE

Animale	Peso (Y)	Torace (X)	Razza	Allevamento	Animale	Peso (Y)	Torace (X)	Razza	Allevamento
a	85.0	101	1	A	m	202.0	134	2	C
b	154.5	119	1	A	n	85.5	103	1	C
c	180.0	134	1	C	o	73.5	96	2	B
d	71.5	92	2	A	p	219.0	148	1	A
e	93.0	110	2	B	q	113.0	108	2	C
f	156.5	135	1	A	r	149.5	120	2	C
g	133.5	119	1	B	s	106.5	107	2	B
h	112.5	114	2	B	t	166.0	134	1	C
i	114.5	115	2	A	u	118.0	116	1	B
l	96.5	105	2	A	v	149.0	126	1	B

Esempio: peso(kg) di 20 bovine dipende dalla circonferenza toracica (covariata) e dal fattore razza che ha 2 livelli ?

$$y_{lmn} = \mu + \alpha_l + bx + e_{lmn}$$

ANOVA MISTA

FATTORIALE + REGRESSIONE

FV	SS	GL	MS	F	P
Circ Toracica	26169	1	26169	169	<0.0001
Tra razze	168	1 (2-1)	168	1.09	0.2978
Circ + Razze	2313	1 (1 * 1)	2313	15.01	0.00094
Errore	2464	16	154		
Totale Corretto	33579	19			

H₀: b = 0, peso non cambia al variare della circonferenza toracica

Circ. Toracica: $F = 26169/145 = 169$;

Sulle tavole $F(1, 16 \text{ GL}; \alpha=0.05) = 4.49 \blacktriangleright 169 > 4.49$ Rifiuto H₀

H₀: le medie delle 2 razze sono uguali

Razza: $F = 168/145 = 1.09$;

Sulle tavole con $F(1, 16 \text{ GL}; \alpha=0.05) = 4.49 \blacktriangleright 1.09 < 4.49$ Accetto H₀

H₀: il modello circonferenza toracica + razze non descrive la variazione del peso

Circ + Razze: $F = 2313/145 = 15.01$;

Sulle tavole $F(1, 16 \text{ GL}, \alpha=0.05) = 4.49 \blacktriangleright 4.49 < 15.01$ Rifiuto H₀

$$R^2 = 31114/33579 = 0.93$$

Il 93% della variabilità del peso è spiegata dal modello utilizzato (razza + circonferenza toracica)

ANOVA MOLTI FATTORI

Modello con molti fattori

Verificare se **l'allevamento** (38 livelli), **l'anno di parto** (14 livelli), il **mese di parto** (4 livelli), il **numero di lattazione** (3 livelli), **l'età al parto in anni** (6 livelli) e i **giorni di lattazione** (12 livelli) mostrano un effetto significativo sulla produzione di latte giornaliera di **4195 capre**. Qual è la parte di variabilità spiegata dal modello adattato?

FV	SS	GL	MS	F	P
Allevamento	8229502	37	222418	31.94	<0.05
Anno di parto	1891133	13	145471	20.08	<0.05
Mese di parto	103661	3	34553	4.96	<0.05
N° lattazione	687796	2	343898	49.39	<0.05
Età al parto	1248578	5	249716	35.86	<0.05
Giorni	357475	11	32498	4.66	<0.05
Errore	28704309	4123	6962		
Totale corretto	61329774	4194			

$$R^2 = 32504780 / 61329774 = \mathbf{0.53}$$